

Hito 3

Planteamiento de la hipótesis y diseño de consultas

Grupo 06: Matias CColque
Benjamín Brito
Gabriel Conejeros
Patricio Rivera

Profesor: Eduardo Godoy V.

Fecha de entrega: 29 de septiembre de 2026

Santiago de Chile

Índice de Contenidos

1. Datasets	1
2. Entidades	2
3. Referencias bibliograficas	4
4. Modelo Entidad-Relación	4
4.1. Diagrama	6
4.2. Restricciones	6
5. Modelo Relacional	6
5.1. Tablas	7
5.2. Formas Normales	7
6. Implementación relacional	8
7. Carga de datos	11
7.1. Carga de la tabla Paradero	11
7.2. Carga de la tabla Viaje	11
7.3. Carga de la tabla Etapas	12
7.4. Carga de la tabla Comuna	12
7.5. Descripción general	12
7.6. Comprobación de la carga de datos	13
8. Estudio de Datos	15
8.1. Hipótesis de estudio	15
8.2. Limitaciones	16
8.3. Consultas	16
8.3.1. Paradas clave	16
8.3.2. Uso del transporte público	16
8.3.3. Combinaciones promedio	17
8.3.4. Demanda por comuna	17
8.3.5. Dispersión del peak	17
8.3.6. Cuánto se viaja?	18
8.4. Optimizaciones	18
8.4.1. Índice por comuna para Paradero	18
8.4.2. Índice por simit para Paradero	18
8.4.3. Índice por id_viaje, dia y horainicio para Viaje	18
8.4.4. Índice por id_viaje y dia para Tiene	19
8.4.5. Índice por simit para Tiene	19
8.4.6. Vista materializada para demanda por paradero y comuna	19

8.4.7. Vista materializada para reducir los JOINS	19
---	----

Índice de Figuras

1. Diagrama Entidad-Relación.	6
2. Comprobación etapa	13
3. Comprobación paradero	13
4. Comprobación pasajero	14
5. Comprobación posee	14
6. Comprobación tiene	15
7. Comprobación viaje	15

Índice de Tablas

1. Entidad: Viaje	2
2. Entidad: Pasajero	2
3. Entidad: Paradero	3
4. Entidad: Etapa	3
5. Entidad: Comuna	4

Índice de Códigos

1. Top 5 paraderos con más subidas en cualquier día para caracterizar zonas de alta demanda.	16
16lstlisting.0.2	
3. Número de etapas promedio por comuna.	17
4. Demanda por cada media hora de cada comuna.	17
5. Veces que se supera la mitad de la demanda peak por comuna	17
6. Distancia promedio recorrida por viaje según cada comuna y su ips.	18
7. Creación de índice para cada comuna en la tabla Paradero.	18
8. Creación de índice para los simit de la tabla Paradero.	18
9. Creación de índice para id_viaje, dia y horainicio para la tabla Viaje.	19
10. Creación de índice para id_viaje y dia para la tabla Tiene.	19
11. Creación de índice para simit para la tabla Tiene.	19
12. Vista materializada de demanda agregada por comuna para el día de estudio .	19
13. Vista materializada de viajes con información socioterritorial asociada	20

1. *Datasets*

La fuente principal utilizada en este análisis proviene de la sección "Matrices de Viaje" del Directorio de Transporte Público Metropolitano (DTPM). Esta plataforma ofrece acceso a tres tipos de bases de datos en formato .csv, .txt y .kmz, con distintos niveles de detalle temporal y espacial de los viajes realizados en el sistema de transporte público metropolitano.

Tipos de datos disponibles:

- **Tabla de Viajes** Contiene registros individuales de viajes realizados por personas. Cada fila representa un viaje con estimaciones del lugar de subida y bajada, junto a la hora de inicio—considerada la hora representativa del viaje.
- **Tabla de Etapas** Constituye un subconjunto de la tabla de viajes, donde cada fila representa una etapa específica del viaje, con información detallada de su origen y destino.
- **Subidas y bajadas por paradero o estación** Se trata de datos agregados que muestran el promedio de subidas y bajadas por intervalo de 30 minutos, identificado según paradero de bus o estación (metro o tren). Las subidas y bajadas son estimadas mediante metodologías específicas descritas más abajo.

Limitaciones y consideraciones metodológicas destacadas. Se tiene la exclusión de viajes no registrados en el sistema de pago, como casos de evasión. Por lo tanto, los datos representan únicamente los viajes que fueron validados a través de medios de pago.

Metodología de asignación de subidas y bajadas (para buses):

- Las subidas se asignan al paradero más cercano hacia atrás en el sentido de avance del servicio, salvo que el bus haya pasado a menos de 50 metros del siguiente paradero, en cuyo caso se asigna al de adelante. Si no hay paradero asignable, queda sin código. En túneles o zonas con pérdida de GPS, puede haber asignación errónea o pérdida de datos.
- Para bajadas, la asignación se basa en el lugar de subida de la siguiente etapa registrada, lo que puede hacerla menos precisa que la de subidas.

Otra fuente utilizada para el estudio de las comunas proviene del contenido sobre el "Índice de Prioridad Social 2024" de la Nube de Inversiones del "Área de Estudios e Inversiones" del Ministerio de Desarrollo Social y Familia (MDSF).

El documento anterior ofrece acceso a los índices de prioridad social (IPS) de las comunas en función de los ingresos, la educación y la salud.

2. Entidades

Al tratarse de una inmensidad de datos, se decidió escoger las variables más características para cada entidad y, asimismo, que tengan una fuerte relación con la motivación del proyecto:

- Viaje(id_viaje, hora_inicio, hora_fin, dist_ruta, paradero_inicio, paradero_fin, num_etapas)

Tabla 1: Entidad: Viaje

Atributo	Descripción	Tipo de dato
id_viaje(llave)	Identificador único del viaje.	Entero
hora_inicio	Hora exacta en la que inicia el viaje.	Hora/Fecha
hora_fin	Hora exacta en la que termina el viaje.	Hora/Fecha
dist_ruta	Distancia total recorrida durante el viaje (en kilómetros).	Decimal
paradero_inicio	Código o identificador del paradero de inicio.	Cadena (String)
paradero_fin	Código o identificador del paradero de finalización.	Cadena (String)
num_etapas	Número de etapas que conforman el viaje.	Entero

- Pasajero(id_tarjeta, comuna*, ...)

Tabla 2: Entidad: Pasajero

Atributo	Descripción	Tipo de dato
id_tarjeta(llave)	Identificador único de la tarjeta del pasajero (anónimo).	Cadena (String)
comuna	Comuna de residencia del pasajero.	Cadena (String)
...	Otros atributos relevantes si se obtienen (por ejemplo, tipo de tarjeta).	Variable

- Paradero(SIMIT, nombre, comuna, media_hora, subidas_promedio, modo, tipo_dia)

Tabla 3: Entidad: Paradero

Atributo	Descripción	Tipo de dato
SIMIT(llave)	Código único que identifica el paradero en el sistema.	Cadena (String)
nombre	Nombre del paradero o estación.	Cadena (String)
comuna	Comuna en la que se ubica el paradero.	Cadena (String)
media_hora	Franja horaria media asociada a la medición.	Entero
subidas_promedio	Número promedio de subidas de pasajeros en ese paradero.	Decimal
modo	Modo de transporte (por ejemplo, bus, metro).	Cadena (String)
tipo_dia	Clasificación del día (laboral, sábado, domingo/festivo).	Cadena (String)

- Etapa(id_etapa, hora_inicio, hora_fin, parada_inicio, parada_fin, dist_ruta)

Tabla 4: Entidad: Etapa

Atributo	Descripción	Tipo de dato
id_etapa(llave)	Identificador único de la etapa.	Entero
hora_inicio	Hora exacta de inicio de la etapa.	Hora/Fecha
hora_fin	Hora exacta de finalización de la etapa.	Hora/Fecha
parada_inicio	Código del paradero de inicio de la etapa.	Cadena (String)
parada_fin	Código del paradero de fin de la etapa.	Cadena (String)
dist_ruta	Distancia recorrida en la etapa (en kilómetros).	Decimal

- Comuna*(nombre, población, km2, ips...)

Tabla 5: Entidad: Comuna

Atributo	Descripción	Tipo de dato
nombre(llave)	Nombre de la comuna.	Cadena (String)
población	Número total de habitantes de la comuna.	Entero
km2	Superficie de la comuna en kilómetros cuadrados.	Decimal
ips	Número que representa la calidad de vida de la comuna (Índice de Prioridad Social).	Decimal
...	Otros datos que se puedan asociar (densidad, región, etc.).	Variable

3. Referencias bibliograficas

- Directorio de Transporte Público Metropolitano (DTPM). (2025, abril 21–27). Tabla de Viajes [Archivo de datos]. En Matrices de Viaje. Recuperado de <https://www.dtpm.cl/index.php/documentos/matrices-de-viaje>
- Directorio de Transporte Público Metropolitano (DTPM). (2025, abril 21–27). Tabla de Etapas [Archivo de datos]. En Matrices de Viaje. Recuperado de <https://www.dtpm.cl/index.php/documentos/matrices-de-viaje>
- Directorio de Transporte Público Metropolitano (DTPM). (2025, abril 21–27). Subidas por Paradero y Estación [Archivo de datos]. En Matrices de Viaje. Recuperado de <https://www.dtpm.cl/index.php/documentos/matrices-de-viaje>
- Ministerio de Desarrollo Social y Familia. (s. f.). Encuesta CASEN 2022. Observatorio Social. Recuperado de <https://observatorio.ministeriodesarrollosocial.gob.cl/encuesta-casen-2022>
- Ministerio de Desarrollo Social y Familia (s. f.). Índice de Prioridad Social de comunas. Recuperado de <https://nubeinversiones.cl/webnube/wp-content/uploads/2024/04/INDICE-DE-PRIORIDAD-SOCIAL-2024.pdf>
- Biblioteca del Congreso Nacional de Chile. (s. f.). Reportes Comunales [página web]. Sistema Integrado de Información Territorial (SIIT). Recuperado de <https://www.bcn.cl/siit/reportescomunales/index.html>

4. Modelo Entidad-Relación

- **Entidades:**
 - Viaje: representa un recorrido completo realizado por un pasajero. Se asocia a uno o varios paraderos de inicio y fin, y está compuesto por varias etapas.

- Pasajero: corresponde a la persona que realiza los viajes.
- Paradero: punto físico de acceso al sistema de transporte, asociado a una comuna.
- Etapa: subdivisión de un viaje, que conecta dos paraderos específicos.
- Comuna: división territorial que agrupa paraderos y permite relacionar información sociodemográfica con la demanda de transporte.

• **Relaciones:**

- Un Pasajero realiza uno o varios Viajes.
- Un Viaje contiene varias Etapas.
- Una Etapa se inicia y termina en un Paradero.
- Un Paradero pertenece a una Comuna.
- **realiza**: vincula a un Pasajero con los Viajes que efectúa.
- **contiene**: un Viaje contiene una o varias Etapas.
- **tiene**: un Viaje se asocia con paraderos de inicio y fin, distinguiendo el rol del paradero mediante el atributo `tipo_paradero`.
- **posee**: cada Etapa se conecta con sus paraderos de inicio y fin, también diferenciados por el atributo `tipo_paradero`.
- **pertenece**: un Paradero pertenece a una única Comuna, mientras que una comuna puede agrupar muchos paraderos.

4.1. Diagrama




Figura 1: Diagrama Entidad-Relación.

4.2. Restricciones

El diagrama modela las restricciones mediante atributos y relaciones.

- **Identificación:** Cada entidad tiene un atributo que es llave primaria.
- **Cardinalidades:** Un pasajero puede realizar muchos viajes, pero cada viajes a un único pasajero. Un viaje puede contener múltiples etapas, y cada etapa está asociada a un único viaje. Cada etapa debe estar conectada a un paradero de inicio y a un paradero de fin. Un paradero pertenece a una sola comuna.
- **Integridad:** el uso de relaciones como **tiene** y **posee** permite asegurar que siempre se diferencien los paraderos de inicio y fin, evitando ambigüedad.

5. Modelo Relacional

5.1. Tablas

- Viaje(id_viaje:int, dist_ruta:float, hora_inicio:time, hora_fin:time, num_etapas:int, tipo_dia:string, REF Pasajero.id_tarjeta)
- Paradero(SIMIT:string, media_hora:int, nombre:string, subidas_promedio:float, modo:string, REF Comuna.nombre)
- Comuna(nombre:string, poblacion:int, km2:float, ips:float)
- Etapa(id_etapa:int, dist_ruta:float, hora_inicio:time, hora_fin:time, REF Viaje.id_viaje)
- Pasajero(id_tarjeta:int)
- Tiene(REF P.SIMIT, REF V.id_viaje, tipo_paradero:string)
- Posee(REF P.SIMIT, REF E.id_etapa, tipo_paradero:string)

5.2. Formas Normales

- **1NF**: Todas las tablas tienen atributos atómicos y sin repetición de grupos.
- **2NF**: No hay dependencias parciales respecto a llaves compuestas, ya que cada atributo no clave depende de la clave primaria completa.
- **3NF**: No existen dependencias transitivas; por ejemplo, en Viaje todos los atributos dependen directamente de id_viaje.
- **BCNF**: En la mayoría de las tablas la clave primaria es la única determinante de los atributos, por lo que también cumplen BCNF. Las tablas de relaciones (**tiene**, **posee**, **pertenece**) mantienen esta propiedad, ya que sus atributos dependen completamente de las claves compuestas.

Lo anterior permite decir que el esquema está en **BCNF**, lo que se sustenta en lo que sigue:

Pasajero: Llave primaria $\rightarrow id_tarjeta$

Dependencias funcionales:

$$id_tarjeta \rightarrow \{\text{todos los atributos}\}$$

No hay más atributos no clave, por lo tanto está en **BCNF**.

Viaje: Llave primaria $\rightarrow id_viaje$

Dependencias funcionales:

$$id_viaje \rightarrow \{dist_ruta, hora_inicio, hora_fin, num_etapas, tipo_dia, id_tarjeta\}$$

No existen dependencias parciales ni transitivas, todos dependen directamente de la clave, por lo tanto está en **BCNF**.

Etapas: Llave primaria $\rightarrow id_etapa$

Dependencias funcionales:

$$id_etapa \rightarrow \{dist_ruta, hora_inicio, hora_fin, id_viaje\}$$

Todos los atributos dependen de la clave, por lo tanto está en **BCNF**.

Paradero: Llave primaria $\rightarrow SIMIT$

Dependencias funcionales:

$$SIMIT \rightarrow \{nombre, modo, media_hora, subidas_promedio\}$$

Todos los atributos dependen de la clave, por lo tanto está en **BCNF**.

Comuna: Llave primaria $\rightarrow nombre$

Dependencias funcionales:

$$nombre \rightarrow \{poblacion, superficie, \dots\}$$

Dependencias directas con la clave, por lo tanto está en **BCNF**.

Relaciones

- **realiza:** ya está implementada en la tabla **Viaje** mediante la FK $id_tarjeta$.
- **contiene:** ya está implementada en la tabla **Etapas** mediante la FK id_viaje .
- **tiene:** Llave $\rightarrow (id_viaje, SIMIT, tipo_paradero)$.
DF: $(id_viaje, SIMIT, tipo_paradero) \rightarrow \emptyset$. Cumple **BCNF**.
- **posee:** Llave $\rightarrow (id_etapa, SIMIT, tipo_paradero)$.
DF: $(id_etapa, SIMIT, tipo_paradero) \rightarrow \emptyset$. Cumple **BCNF**.
- **pertenece:** Llave $\rightarrow (SIMIT, nombre_comuna)$. No hay más atributos, cumple **BCNF**.

6. Implementación relacional

A continuación se presentan las sentencias SQL utilizadas para crear el esquema relacional que implementa el modelo presentado en las secciones previas. Se incluye la eliminación previa de tablas existentes para permitir ejecuciones repetidas del script sin errores de dependencia.

```
1 CREATE TABLE Comuna(  
2   nombre VARCHAR(255) PRIMARY KEY,
```

```
3  poblacion INT,
4  km2 FLOAT,
5  ips FLOAT,
6  CONSTRAINT comuna_pk PRIMARY KEY (nombre)
7 );
8
9 CREATE TABLE Pasajero(
10 id_tarjeta INT,
11 CONSTRAINT pasajero_pk PRIMARY KEY (id_tarjeta)
12 );
13
14 CREATE TABLE Viaje(
15 id_viaje INT,
16 ruta_dist FLOAT,
17 dia DATE,
18 hora_inicio TIME,
19 hora_fin TIME,
20 num_etapas INT,
21 tipo_dia INT,
22 id_tarjeta INT,
23 CONSTRAINT viaje_id_dia_hora_inicio_pk PRIMARY KEY (id_viaje, dia),
24 CONSTRAINT viaje_tarjeta_fk FOREIGN KEY (id_tarjeta)
25 REFERENCES Pasajero(id_tarjeta)
26 );
27
28 CREATE TABLE Etapa(
29 id_etapa INT,
30 dist_ruta FLOAT,
31 dia DATE,
32 hora_inicio TIME,
33 hora_fin TIME,
34 id_viaje INT,
35 CONSTRAINT etapa_id_dia_hora_inicio_pk PRIMARY KEY (id_etapa, dia,
36 ↪ hora_inicio),
37 CONSTRAINT etapa_viaje_dia_fk FOREIGN KEY (id_viaje, dia)
38 REFERENCES Viaje(id_viaje, dia)
39 );
40
41 CREATE TABLE Paradero(
42 simit VARCHAR(255),
43 dia DATE,
44 media_hora TIME,
45 nombre_comuna VARCHAR(255),
46 subidas_promedio FLOAT,
47 modo VARCHAR(255),
48 CONSTRAINT paradero_pk PRIMARY KEY (simit, dia, media_hora),
49 CONSTRAINT paradero_comuna_fk FOREIGN KEY (nombre_comuna)
```

```
49     REFERENCES Comuna(nombre)
50 );
51
52 CREATE TABLE Tiene(
53     tipo_paradero VARCHAR(255),
54     simit VARCHAR(255),
55     id_viaje INT,
56     dia DATE,
57     CONSTRAINT tiene_simit_fk FOREIGN KEY (simit)
58     REFERENCES Paradero(simit),
59     CONSTRAINT tiene_viaje_fk FOREIGN KEY (id_viaje, dia)
60     REFERENCES Viaje(id_viaje, dia)
61 );
62
63 CREATE TABLE Posee(
64     tipo_paradero VARCHAR(255),
65     simit VARCHAR(255),
66     id_etapa INT,
67     dia DATE,
68     hora_inicio TIME,
69     CONSTRAINT posee_simit_fk FOREIGN KEY (simit)
70     REFERENCES Paradero(simit),
71     CONSTRAINT posee_etapa_fk FOREIGN KEY (id_etapa, dia, hora_inicio)
72     REFERENCES Etapa(id_etapa, dia, hora_inicio)
73 );
```

Notas sobre diseño

- En las tablas **Viaje** y **Etapa** se definen claves primarias compuestas que incluyen el identificador y la fecha (e incluso la hora en **Etapa**), con el propósito de asegurar la unicidad diaria de los registros y mantener coherencia entre los viajes y las etapas de un mismo día.
- La tabla **Paradero** incorpora una clave primaria compuesta (**simit**, **dia**, **media_hora**) para reflejar la agregación temporal de los datos de subidas promedio por paradero y franja horaria.
- Las tablas **Tiene** y **Posee** establecen relaciones entre **Viaje-Paradero** y **Etapa-Paradero**, respectivamente, mediante claves foráneas que enlazan con las claves compuestas de las tablas principales.
- Se mantiene una estructura relacional normalizada que evita la redundancia y permite mantener la integridad referencial entre las entidades del sistema de transporte.
- El uso de claves foráneas garantiza la consistencia entre los viajes, etapas y paraderos, asegurando que las referencias solo correspondan a registros válidos en las tablas relacionadas.

- Aunque no se declaran restricciones `NOT NULL` explícitas en todas las columnas, estas pueden añadirse en una etapa posterior para fortalecer las reglas de integridad y optimizar el rendimiento en consultas.

7. Carga de datos

La carga de datos se implementó mediante un script en **Python** que utiliza la librería **psycopg2** para conectarse al servidor PostgreSQL y ejecutar las sentencias de inserción en las tablas del esquema **transporte**. Asimismo, se emplean las librerías **csv**, **pandas**, **pathlib** y **datetime** para la lectura, organización y transformación de los archivos de entrada, provenientes de diferentes fuentes de información del sistema de transporte público.

El script procesa tres fuentes principales de información:

- Los archivos de la carpeta **Tabla-de-Viajes-ABR25**, que contienen los datos de viajes y las características asociadas a cada uno.
- Los archivos de la carpeta **Tabla-de-Etapas-ABR25**, que detallan las etapas que componen cada viaje.
- El archivo **Subida_Paradero_Estacion_2025_04_v2.xlsb**, que almacena los registros de subidas promedio por paradero y franja horaria.

Las rutas de las carpetas se definen al inicio del script, permitiendo un acceso estructurado y modular a las distintas fuentes de datos.

7.1. Carga de la tabla Paradero

En primer lugar, se realiza la carga del archivo de paraderos utilizando la librería **pandas**. El código recorre la hoja **SUBIDAS_2025_04** del archivo en formato **.xlsb**, extrayendo las columnas de interés. El campo **día** se calcula dinámicamente a partir del cambio de la franja horaria (**media_hora**), asegurando que las observaciones se asignen al día correcto.

7.2. Carga de la tabla Viaje

Una vez cargados los paraderos, el script procede con la carga de los viajes. Cada archivo CSV en la carpeta correspondiente se asocia a una fecha, la cual se utiliza como clave dentro de un diccionario que facilita la búsqueda de datos relacionados con las etapas.

El proceso recorre los archivos de viajes, omitiendo el día 23 por no tener información de etapas asociadas. Por cada registro, se insertan los datos en las tablas **Pasajero**, **Viaje** y **Tiene**. Primero se registra el identificador de tarjeta del pasajero, luego los atributos del viaje (distancia, día, hora de inicio y término, número de etapas y tipo de día), y finalmente se construye la relación **Tiene** que vincula el viaje con su paradero de inicio.

7.3. Carga de la tabla Etapa

La siguiente etapa del proceso carga los datos de las etapas correspondientes a cada viaje. El script abre simultáneamente el archivo de etapas y su archivo de viajes asociado (según la fecha), estableciendo así la relación entre ambos. Cada registro de etapa incluye los atributos `id_etapa`, `dist_ruta`, `dia`, `hora_inicio`, `hora_fin` e `id_viaje`, además de la información de paradero y tipo de transporte utilizado.

Durante la ejecución, el programa identifica el viaje al que pertenece cada etapa comparando el código del operador de la etapa con los operadores presentes en el archivo de viajes. Una vez determinada esta correspondencia, se realiza la inserción en las tablas **Etapa** y **Posee**, garantizando la integridad referencial entre ambas.

7.4. Carga de la tabla Comuna

Finalmente, se copia de forma exhaustiva y manual la información relevante de cada comuna de los Reportes Comunales y se agrega el dato de ips de cada una, proveniente del documento del INDICE-DE-PRIORIDAD-SOCIAL-2024.

7.5. Descripción general

- El proceso de carga automatiza la lectura de datos y su inserción en las tablas correspondientes, garantizando la trazabilidad entre los niveles de información (paraderos, viajes y etapas).
- La correspondencia temporal se mantiene mediante el atributo `dia`, que actúa como elemento unificador entre los distintos conjuntos de datos.
- Se incluye un control de errores mínimo (por ejemplo, exclusión del día sin archivo de etapas) para evitar conflictos de integridad referencial durante la ejecución.
- El uso de librerías estándar de Python proporciona un flujo reproducible, flexible y adaptable ante posibles cambios en las estructuras de los archivos fuente.

7.6. Comprobación de la carga de datos

```
cc3201=# SELECT * FROM etapa LIMIT 10;
```

id_etapa	dist_ruta	día	hora_inicio	hora_fin	id_viaje
66184	853	2025-04-21	08:48:04	08:50:39	1
66184	1090	2025-04-21	08:51:46	08:54:58	
66184	1127	2025-04-21	15:34:28	15:39:01	
67208		2025-04-21	17:27:55		
70536	6240	2025-04-21	09:12:16	09:38:40	
70536	11630	2025-04-21	10:49:35	11:17:20	
70536	24970	2025-04-21	11:45:44	12:33:36	
70536	16140	2025-04-21	13:42:08	14:18:40	
70536	4475	2025-04-21	14:40:37	14:54:18	
70536	1277	2025-04-21	15:13:40	15:16:44	

(10 rows)

Figura 2: Comprobación etapa

```
cc3201=# SELECT * FROM paradero LIMIT 10;
```

simit	día	media_hora	nombre_comuna	subidas_promedio	modo
E-10-71-OP-21	2025-04-21	00:30:00	PUDAHUEL	1	BUS
E-10-71-OP-21	2025-04-21	06:00:00	PUDAHUEL	5	BUS
E-10-71-OP-21	2025-04-21	06:30:00	PUDAHUEL	14	BUS
E-10-71-OP-21	2025-04-21	07:00:00	PUDAHUEL	9	BUS
E-10-71-OP-21	2025-04-21	07:30:00	PUDAHUEL	26	BUS
E-10-71-OP-21	2025-04-21	08:00:00	PUDAHUEL	18	BUS
E-10-71-OP-21	2025-04-21	08:30:00	PUDAHUEL	13	BUS
E-10-71-OP-21	2025-04-21	09:00:00	PUDAHUEL	4	BUS
E-10-71-OP-21	2025-04-21	09:30:00	PUDAHUEL	12	BUS

(10 rows)

Figura 3: Comprobación paradero

```
cc3201=# SELECT * FROM pasajero LIMIT 10;
id_tarjeta
-----
      66184
      67208
      70536
      73608
     134536
     135048
     135816
     140424
     140680
     141960
(10 rows)
```

Figura 4: Comprobación pasajero

```
cc3201=# SELECT * FROM posee LIMIT 10;
tipo_paradero |      simit      | id_etapa |      dia      | hora_inicio
-----+-----+-----+-----+-----
BUS            | T-4-19-SN-40    |    66184 | 2025-04-21    | 08:48:04
BUS            | E-4-19-SN-55    |    66184 | 2025-04-21    | 08:51:46
BUS            | L-4-12-20-PO    |    66184 | 2025-04-21    | 15:34:28
METRO          | LOS DOMINICOS   |    67208 | 2025-04-21    | 17:27:55
METRO          | ESTACION CENTRAL |    70536 | 2025-04-21    | 09:12:16
METRO          | PLAZA DE ARMAS  |    70536 | 2025-04-21    | 10:49:35
METRO          | BELLAVISTA DE LA FLORIDA | 70536 | 2025-04-21    | 11:45:44
METRO          | MONTE TABOR     |    70536 | 2025-04-21    | 13:42:08
BUS            | T-14-131-PO-10  |    70536 | 2025-04-21    | 14:40:37
BUS            | T-15-135-PO-5   |    70536 | 2025-04-21    | 15:13:40
(10 rows)
```

Figura 5: Comprobación posee

```
cc3201=# SELECT * FROM tiene LIMIT 10;
```

tipo_paradero	simit	id_viaje	dia
1	T-4-19-SN-40	1	2025-04-21
1	L-4-12-20-PO	2	2025-04-21
2	LOS DOMINICOS	1	2025-04-21
2	ESTACION CENTRAL	1	2025-04-21
2	PLAZA DE ARMAS	2	2025-04-21
2	BELLAVISTA DE LA FLORIDA	3	2025-04-21
2	MONTE TABOR	4	2025-04-21
1	T-15-135-PO-5	5	2025-04-21
1	L-17-8-15-OP	6	2025-04-21
2	ESCUELA MILITAR	7	2025-04-21

(10 rows)

Figura 6: Comprobación tiene

```
cc3201=# SELECT * FROM viaje LIMIT 10;
```

id_viaje	ruta_dist	dia	hora_inicio	hora_fin	num_etapas	tipo_dia	id_tarjeta
1	1943	2025-04-21	08:48:04	08:54:58	2	0	66184
2	1127	2025-04-21	15:34:28	15:39:01	1	0	66184
3	24970	2025-04-21	11:45:44	12:33:36	1	0	70536
4	20615	2025-04-21	13:42:08	14:54:18	2	0	70536
5	1596	2025-04-21	15:13:40	15:20:56	2	0	70536
6	1859	2025-04-21	16:03:06	16:10:38	1	0	70536
7	10050	2025-04-21	16:30:50	16:56:32	1	0	70536
8	1530	2025-04-21	12:55:42	13:06:08	1	0	16322184
9	14200	2025-04-21	13:13:21	13:56:48	1	0	16322184
10	0	2025-04-21	16:57:15		1	0	16322184

(10 rows)

Figura 7: Comprobación viaje

8. Estudio de Datos

A continuación, se presenta el caso de estudio centrado en el análisis de los patrones de movilidad que múltiples personas tienen en el transporte público a lo largo de una semana.

El objetivo es identificar regularidades, variaciones y anomalías en los desplazamientos, con el fin de comprender mejor el uso del espacio y del tiempo en el transporte público.

8.1. Hipótesis de estudio

Se puede establecer una relación entre los patrones de desplazamiento de los sectores y su nivel de calidad de vida. Particularmente, se espera que los grupos con mayor prioridad social

exhiban horarios de viaje más concentrados en períodos específicos del día —principalmente horas punta laborales— mientras que los grupos con menor prioridad social presenten patrones temporales más dispersos y flexibles.

8.2. Limitaciones

La mayor limitación a la que nos enfrentamos es el tipo de registro bajo el cuál se realiza nuestro estudio, ya que, este se limita al registro de los viajes realizados formalmente, es decir, aquellos que son pagados, obviando así las evasiones que también afectan a la dinámica del transporte público.

Otra limitación se centra en la representatividad que puede tener el estudio. Dado que el periodo estudiado se reduce a una sola semana, esta puede no capturar variaciones provocadas por eventos masivos, el clima, feriados, etc. La estabilidad de los patrones rescatados puede ser cuestionable.

8.3. Consultas

8.3.1. Paradas clave

Identificar los paraderos más utilizados, independiente del día. Estos puntos suelen corresponder a zonas de alta concentración de viajes, actividad laboral o intermodalidad.

Código 1: Top 5 paraderos con más subidas en cualquier día para caracterizar zonas de alta demanda.

```
1 SELECT simit, nombre_comuna, SUM(subidas_promedio) AS total_subidas
2 FROM Paradero
3 GROUP BY simit, nombre_comuna
4 ORDER BY total_subidas DESC
5 LIMIT 5;
```

8.3.2. Uso del transporte público

Determinar si las zonas más vulnerables presentan un mayor volumen de subidas, lo cual puede evidenciar una dependencia más fuerte del transporte público.

Código 2: Paraderos con mayor demanda en comunas vulnerables para ver si las comunas con IPS alto concentran mayor volumen de subidas.

```
1 SELECT p.nombre_comuna, c.ips, SUM(p.subidas_promedio) AS total_subidas
2 FROM Paradero p
3 JOIN Comuna c ON c.nombre = p.nombre_comuna
4 GROUP BY p.nombre_comuna, c.ips
5 HAVING SUM(p.subidas_promedio) > (
6     SELECT AVG(subidas_promedio)
```

```

7 FROM Paradero
8 )
9 ORDER BY c.ips DESC, total_subidas DESC;

```

8.3.3. Combinaciones promedio

Determinar el número promedio de etapas por comuna para comparar el nivel de prioridad con que tan fraccionados son los trayectos que deben recorrer.

Código 3: Número de etapas promedio por comuna.

```

1 SELECT c.nombre, c.ips, AVG(v.num_etapas) AS etapas_promedio
2 FROM Viaje v
3 JOIN Tiene t ON t.id_viaje = v.id_viaje AND t.dia = v.dia
4 JOIN Paradero p ON p.simit = t.simit
5 JOIN Comuna c ON c.nombre = p.nombre_comuna
6 GROUP BY c.nombre, c.ips
7 ORDER BY etapas_promedio DESC;

```

8.3.4. Demanda por comuna

Determinar la demanda por hora del transporte público para cada comuna. Muestra de forma precisa la densidad de gente por comuna en diferentes horarios, particularmente, horarios peak.

Código 4: Demanda por cada media hora de cada comuna.

```

1 SELECT c.nombre, p.media_hora, SUM(p.subidas_promedio) AS demanda_media_hora
2 FROM Paradero p
3 JOIN Comuna c ON c.nombre = p.nombre_comuna
4 GROUP BY c.nombre, p.media_hora
5 ORDER BY c.nombre, p.media_hora

```

8.3.5. Dispersión del peak

Se busca determinar cuantas veces se supera (en media hora) la mitad de la demanda peak de una comuna, esto pues creemos que es un buen reflejo de peaks menos agudos, de una distribución más pareja de la demanda por transporte público, atacando directamente a nuestra hipótesis. (DemandaComuna es el resultado del query anterior)

Código 5: Veces que se supera la mitad de la demanda peak por comuna

```

1 SELECT D.nombre, COUNT(D.demanda_media_hora)
2 FROM DemandaComuna D, (SELECT DISTINCT(nombre), demanda_media_hora AS
   ↪ peak FROM DemandaComuna ORDER BY demanda_media_hora DESC) P
3 WHERE D.nombre=P.nombre AND D.demanda_media_hora> P.peak/2
4 GROUP BY D.nombre

```

8.3.6. Cuánto se viaja?

Determinar la distancia promedio recorrida por viaje según comuna. Notar la diferencia entre comunas periféricas de alta prioridad con el resto. En busca de excluir el regreso a casa se toman solo datos del transporte durante el horario AM.

Código 6: Distancia promedio recorrida por viaje según cada comuna y su ips.

```
1 SELECT c.nombre, c.ips, AVG(v.ruta_dist) AS distancia_promedio
2 FROM Viaje v
3 JOIN Tiene t ON v.id_viaje = t.id_viaje AND v.dia = t.dia
4 JOIN Paradero p ON p.simit = t.simit
5 JOIN Comuna c ON c.nombre = p.nombre_comuna
6 WHERE v.hora_inicio < '12:00:00'
7 GROUP BY c.nombre, c.ips
8 ORDER BY distancia_promedio DESC;
```

8.4. Optimizaciones

Con el objetivo de acelerar la recuperación de datos y optimizar el rendimiento de algunas consultas se pueden definir los siguientes índices y vistas materializadas.

8.4.1. Índice por comuna para Paradero

Se pide frecuentemente las comunas de la tabla paradero.

Código 7: Creación de índice para cada comuna en la tabla Paradero.

```
1 CREATE INDEX idx_paradero_comuna
2 ON Paradero(nombre_comuna);
```

Se utiliza en las consultas 8.3.1, 8.3.2 y 8.3.4.

8.4.2. Índice por simit para Paradero

Se consulta el simit de cada paradero en los joins con las tablas Tiene y Posee.

Código 8: Creación de índice para los simit de la tabla Paradero.

```
1 CREATE INDEX idx_paradero_simit
2 ON Paradero(simit);
```

Se utiliza en las consultas 8.3.1 y 8.3.2.

8.4.3. Índice por id_viaje, dia y horainicio para Viaje

Se hace JOIN con la tabla Tiene en *(id_viaje, dia)* y se filtra por *hora_inicio*.

Código 9: Creación de índice para *id_viaje*, *dia* y *horainicio* para la tabla *Viaje*.

```
1 CREATE INDEX idx_viaje_id_dia_horainicio
2 ON Viaje(id_viaje, dia, horainicio);
```

Se utiliza en las consultas 8.3.3 y 8.3.6.

8.4.4. Índice por *id_viaje* y *dia* para *Tiene*

Análoga al anterior, los JOIN con la tabla *Tiene* bajo (*id_viaje*, *dia*) son pesados y pueden ser optimizados.

Código 10: Creación de índice para *id_viaje* y *dia* para la tabla *Tiene*.

```
1 CREATE INDEX idx_tiene_idviaje_dia
2 ON Tiene(id_viaje, dia);
```

Se utiliza en las consultas 8.3.3 y 8.3.6.

8.4.5. Índice por *simit* para *Tiene*

Los JOIN con la Tabla *Tiene* bajo *simit* también son pesados.

Código 11: Creación de índice para *simit* para la tabla *Tiene*.

```
1 CREATE INDEX idx_tiene_simit
2 ON Tiene(simit);
```

Se utiliza en las consultas 8.3.3 y 8.3.6.

8.4.6. Vista materializada para demanda por paradero y comuna

Con el fin de reducir el tiempo de ejecución de la consulta

Código 12: Vista materializada de demanda agregada por comuna para el día de estudio

```
1 CREATE MATERIALIZED VIEW demanda_paradero AS
2 SELECT p.simit, p.nombre_comuna, SUM(p.subidas_promedio) AS total_subidas
3 FROM Paradero p
4 GROUP BY p.simit, p.nombre_comuna;
```

Esta vista materializada pre-calcula la demanda total de transporte público por comuna para el día analizado, optimizando las consultas 8.3.2, 8.3.4 y 8.3.5 que requieren agregaciones a nivel comunal.

8.4.7. Vista materializada para reducir los JOINS

Las consultas diseñadas que mezclan *Viaje-Tiene-Paradero-Comuna* involucran 3 JOINS, lo que es costoso

Código 13: Vista materializada de viajes con información socioterritorial asociada

```
1 CREATE MATERIALIZED VIEW viajes_y_comuna AS
2 SELECT v.id_viaje, v.dia, v.hora_inicio, v.ruta_dist, v.num_etapas, c.nombre AS comuna,
   ↪ c.ips
3 FROM Viaje v
4 JOIN Tiene t ON t.id_viaje = v.id_viaje AND t.dia = v.dia
5 JOIN Paradero p ON p.simit = t.simit
6 JOIN Comuna c ON c.nombre = p.nombre_comuna
```

Esta vista materializada optimiza las consultas 8.3.3, 8.3.6 y cualquier análisis que relacione patrones de viaje con indicadores socioterritoriales. Al precalcular los JOINS entre Viaje-Tiene-Paradero-Comuna, eliminamos la necesidad de ejecutar múltiples uniones en tiempo real, acelerando significativamente consultas que analizan la relación entre comportamiento de movilidad y características comunales como el IPS