

Tarea 1

Fecha de entrega: 13 de abril, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Álvaro Márquez, Diego Olguín Wende

Ayudantes: Tamara Carrasco, Javiera Yáñez

Formato de entrega	PDF con extensión máxima de 8 páginas, con anexos, con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1 (20 %) - Regresión lineal y descomposición sesgo-varianza

Consideremos el caso en el que intentamos estimar una función $g(z) = 3z^2$, para $z \in \mathbb{R}$ usando un modelo de regresión lineal $h(z) = \theta z$, basado en un conjunto de puntos $x \in \mathbb{R}$ muestreados de una distribución $\mathcal{U}(0, 1)$ (le puede servir que en tal caso $\mathbb{E}(x) = \frac{1}{2}$ y $\mathbb{E}(x^2) = \frac{1}{3}$). Cada punto está asociado a una etiqueta $y = g(x)$ libre de ruido. Asumimos que entrenamos el modelo lineal $h(\cdot)$ solamente con un punto de dato $x \neq 0$, usando mínimos cuadrados.

- (a) **(0.5 puntos)** Explicar brevemente por qué este modelo lineal $h(z)$ tendrá un sesgo elevado.
- (b) **(1.5 puntos)** Calcule el coeficiente de regresión θ .
- (c) **(1 punto)** ¿Cuál es el sesgo de $h(z)$? Esto debe ser expresado en función de un punto de dato $z \in \mathbb{R}$, sin incluir ninguna componente con x .
- (d) **(1 punto)** De manera análoga, escribir la varianza del modelo en función de $z \in \mathbb{R}$.
- (e) **(1 punto)** $E(h, z)$ es el error cuadrático medio de un punto de testeo $z \in \mathbb{R}$. Escriba la relación entre $E(h, z)$ y el sesgo y varianza en z . Calcular el valor preciso de los tres términos anteriores para el caso $z = 1$.

- (f) **(0.5 puntos)** Aborde el problema de selección de características, ¿Cómo se podría mejorar el modelo?
- (g) **(0.5 puntos)** Piense en qué fenómeno se podría modelar con el enunciado. ¿Qué podría la regresión lineal aportar al estudio del fenómeno? ¿qué otras consideraciones (como la capacidad computacional o la interpretación de resultados) podrían influir en la elección de un modelo simple como la regresión lineal para un problema complejo?

P2 (30 %) - Regresión Lineal Bayesiana

Sea X una variable aleatoria en $\mathbb{R}^p$ e Y variable aleatoria a valores $\mathbb{R}$. Consideremos el modelo de regresión lineal:

$$Y = \beta_0 + \beta^T X + \epsilon, \text{ con } \epsilon \sim \mathcal{N}(0, \sigma^2),$$

con $\beta = (\beta_1, \dots, \beta_p)^T$. Suponemos σ^2 conocido. Nos interesamos en la estimación Bayesiana de los parámetros $\theta = (\beta_0, \beta_1, \dots, \beta_p)$. Suponemos que la distribución X no depende de θ . Sean $(x_i, y_i)_{1 \leq i \leq N}$ datos.

- (a) **(1 punto)** Demuestre que el estimador *máximo a posteriori* con un prior constante uniforme (que no depende de θ) equivale al estimador de máxima verosimilitud.

Supongamos que usamos el siguiente prior independiente sobre cada coeficiente β_i , para $i = 1, \dots, p$ (es decir, el intercepto β_0 no se penaliza):

$$p(\beta_i) = \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{\beta_i^2}{2\tau^2}}$$

- (b) **(2 puntos)** Encuentre el estimador *máximo a posteriori*. Identifique a qué estimador conocido corresponde.
- (c) **(2 puntos)** Considere los casos
- $\tau \rightarrow \infty$
 - $\tau \rightarrow 0$

Argumente qué sucede en cada caso, tanto en términos del estimador encontrado, como en términos “Bayesianos” (esto es, piense en la forma que tendrían los priors en ambos casos). ¿Son los casos presentados esperables en la realidad? Comente.

Ahora denote $\rho = \frac{\sigma^2}{\tau^2}$, que lo interpretaremos como un hiper-parámetro de nuestro modelo.

- (d) **(1 punto)** Demuestre que el estimador resultante de la minimización es insesgado si y sólo si $\rho = 0$. ¿Es lo anterior, en la práctica, posible? Dé un caso práctico y discuta.

P3 (50 %) - Regresión lineal, caso aplicado

En el archivo `Musical_Instruments.jsonl` encontrará un conjunto de datos que contiene reseñas de instrumentos musicales de *Amazon*¹. Para el desarrollo de las siguientes preguntas ocupe sólo un 50 % de estos datos, eligiéndolos aleatoriamente usando su rut (sin verificador) como semilla aleatoria.

- (a) **(0.5 puntos)** Implemente la clase `LinearRegression` utilizando como base los métodos que se describen en el código entregado al final de la tarea. La función `fit` debe implementar la estimación de $\hat{\theta}_{MC}$ mediante Mínimos Cuadrados y `predict` debe utilizar $\hat{\theta}_{MC}$ para realizar una predicción. Esta clase deberá ser utilizada para el resto de la tarea, a menos que se le indique lo contrario. Para implementar esta clase solo utilice la librería `numpy`.

Consideremos un modelo de regresión lineal simple (mínimos cuadrados ordinarios, MCO) para predecir la calificación por estrellas de cada reseña utilizando solo tres características del conjunto de datos. Consideramos entonces que la etiqueta y_{sr} , que corresponde a la columna `rating` (cantidad de estrellas), estará dada por:

$$y_{sr} = \theta_0 + \theta_1 x_{vp} + \theta_2 x_{hv} + \theta_3 x_{lr} + \epsilon,$$

donde x_{vp} corresponderá a la columna `verified_purchase`, x_{hv} a la columna `helpful_vote` y x_{lr} a la columna `length_of_review` (creada por usted). Para esta última característica utilice alguna heurística que considere adecuada (por ejemplo, el número de palabras o caracteres de la reseña). Por otro lado, $\theta_0, \theta_1, \theta_2$ y θ_3 son los parámetros del modelo y $\epsilon \sim \mathcal{N}(0, \sigma^2)$ corresponde al ruido.

- (b) **(0.5 puntos)** ¿Cuál es la distribución de las calificaciones en el conjunto de datos? Genere un histograma, calcule además métricas de interés, como el promedio y la varianza, comente al respecto. ¿Es esperable que un modelo de regresión lineal tenga un buen ajuste? ¿Por qué?
- (c) **(0.5 puntos)** Divida su conjunto de datos en dos, considerando un 80 % para entrenamiento y el 20 % restante para prueba. Entrene el modelo por mínimos cuadrados en el dataset de entrenamiento y reporte los valores de $\theta_0, \theta_1, \theta_2$ y θ_3 . Dé una breve explicación de estos parámetros (i.e., que es lo que representan con respecto a cada una de las características). Reporte la raíz cuadrada del error cuadrático medio (RMSE), el error cuadrático medio (ECM), el error absoluto medio (MAE) y el coeficiente de determinación (R^2) del modelo en el conjunto de entrenamiento y en el de prueba por separado. Explique los resultados obtenidos.
- (d) **(1 punto)** Implemente LASSO y Ridge Regression. Utilice distintos valores para el hiperparámetro de regularización λ y grafique el ECM en función de éste para ambos datasets (entrenamiento y prueba). Grafique la norma de los parámetros encontrados para los distintos modelos e indique qué puede observar de las magnitudes obtenidas para cada método. En esta parte puede usar la librería `sklearn`. Compare los resultados con lo obtenido en la parte anterior. ¿Qué características de este dataset explican que ciertos parámetros se reduzcan a cero más rápidamente en Lasso que en Ridge? ¿Qué diferencias entre las métricas obtenidas en los conjuntos de entrenamiento y prueba se observan entre los modelos LASSO, Ridge y MCO?
- (e) **(0.5 puntos)** Calcule y analice la matriz de correlaciones entre las variables predictoras utilizadas. ¿Se observa algún nivel de multicolinealidad significativo? Explique cómo afectaría la multicolinealidad al estimador de mínimos cuadrados y cómo métodos como Ridge o Lasso pueden mitigar este efecto.

¹ Para más detalles, puede ver la página oficial del dataset [Amazon Reviews 2023](#)

- (f) **(1 punto)** Repita los pasos anteriores, pero aplicando un escalado a los datos. Le puede ser útil la librería *sklearn.preprocessing*, donde se recomienda solo estandarizar la matriz de diseño X (usando *sklearn.preprocessing.StandardScaler*). ¿Son las métricas calculadas comparables? ¿Qué sucede con los parámetros estimados al escalar los datos? ¿Por qué ocurren estas diferencias/similitudes? ¿Qué diferencias entre las métricas obtenidas en los conjuntos de entrenamiento y prueba se observan entre los modelos LASSO, Ridge y MCO?
- (g) **(1 punto)** Agregue como variables al modelo el número del mes y el número del año en el que se publicó la review para estimar la clasificación por estrellas. ¿Es esperable que estas variables aporten significativamente desde un punto de vista teórico-estadístico? Implemente una regresión lineal, Lasso, Ridge y ElasticNet (que combina las penalizaciones L_1 y L_2). Reporte la raíz cuadrada del error cuadrático medio (RMSE), el error cuadrático medio (ECM), el error absoluto medio (MAE) y el coeficiente de determinación (R^2) del modelo en el conjunto de entrenamiento y en el de prueba por separado. Explique los resultados obtenidos. ¿Qué se puede interpretar de la contribución de estas nuevas variables al modelo? ¿Qué limitaciones tiene el modelo al incluir estas variables? ¿Qué diferencias entre las métricas obtenidas en los conjuntos de entrenamiento y prueba se observan entre los modelos LASSO, Ridge, ElasticNet y MCO?
- (h) **(1 punto)** De todos los modelos/métodos de regresión utilizados indique cuál recomendaría usted. Fundamente su respuesta. A partir de los resultados obtenidos para RMSE, ECM, MAE y R^2 , explique cuál de estas métricas es más robusta desde el punto de vista estadístico ante la distribución observada en los datos reales. Considerando lo estudiado en P2, ¿qué prior podría asignar sobre los parámetros del modelo y qué interpretación tendría la distribución posterior resultante? ¿Cómo se relaciona el estimador MAP con los métodos de regularización utilizados en esta pregunta?
- (i) **(Bonus, 2 puntos)**² Valide empíricamente los supuestos clave del modelo de regresión lineal utilizando gráficos y análisis estadísticos. Entregue:
- Gráfico de residuos vs predicciones para validar homocedasticidad.
 - Gráficos de dispersión de cada variable predictora vs variable dependiente (rating) para validar linealidad.
 - Un gráfico Q-Q plot para evaluar normalidad de los errores.

Discuta en detalle sus resultados. ¿Qué conclusiones obtiene acerca de la pertinencia del modelo lineal? ¿Qué implicaciones tienen los resultados obtenidos para la calidad del modelo y la validez estadística de sus conclusiones?

Estructura para la clase `LinearRegression`

```

1 class LinearRegression:
2
3     def __init__(self):
4         pass
5
6     def fit(self, X, y):
7         pass
8
9     def predict(self, X):
10        pass

```

² Se agrega a la pregunta con menor puntaje