
Tarea 1: Regresión Lineal

Magíster en Ciencia de Datos

Autor: Matias CColque Antachoque¹ Profesor: Francisco Vásquez L.¹

Abstract

This document provides a basic paper template and submission guidelines. Abstracts must be a single paragraph, ideally between 4–6 sentences long. Gross violations will trigger corrections at the camera-ready phase.

P1. Regresión lineal y descomposición sesgo-varianza

P1.1. Sesgo elevado en $h(z)$

Al tratar de explicar o estimar una función cuadrática $g(z)$ que posee el compartamiento de una curva, con una función lineal $h(z)$ que posee la forma de una recta, evidentemente generará un alto sesgo pues el modelo lineal no posee suficiente flexibilidad y no representa correctamente la forma de la cuadrática. Esto es similar a un caso de underfitting.

P1.2. Cálculo del coeficiente θ

Por el método de MCO para obtener el parámetro θ es necesario minimizar la suma de errores cuadrados. Como se entrena únicamente un dato $x \neq 0$, y sabemos que este punto está asociado a una etiqueta $y = g(x)$, se puede aplicar MCO a esta observación y obtener el coeficiente solicitado. Entonces:

$$\begin{aligned} \Rightarrow (y - \hat{y})^2 & \quad \text{/Error o Residuo cuadrado} \\ = (3x^2 - \theta x)^2 & \quad \text{/Definición} \\ \Rightarrow \min_{\theta} (3x^2 - \theta x)^2 & \quad \text{/Aplicando MCO} \\ = \frac{d}{d\theta} (3x^2 - \theta x)^2 & \quad \text{/Minimización con datos lineales} \\ \Rightarrow 2(\theta x - 3x^2) \cdot x = 0 & \quad \text{/Cond. Primer Orden} \\ \Leftrightarrow \theta = 3x & \quad \text{/Resolución} \end{aligned}$$

^{*}Equal contribution ¹Universidad de Chile, Santiago, Chile. Correspondence to: Matias CColque A. <matias.ccolque@ug.uchile.cl>.

P1.3. Sesgo de $h(z)$

Utilizando la fórmula del sesgo para modelos de predicciones, y los valores dados de la esperanza de la muestra ($\mathbb{E}[x] = \frac{1}{2}$), se obtiene que el sesgo es:

$$\begin{aligned} \text{Sesgo}(h(z)) &= \mathbb{E}[h(z)] - g(z) = \mathbb{E}[3xz] - 3z^2 = 3z \mathbb{E}[x] - 3z^2 \\ \Rightarrow \text{Sesgo}(h(z)) &= \frac{3}{2}z - 3z^2 \end{aligned}$$

P1.4. Varianza de $h(z)$

Utilizando la definición clásica de varianza con el modelo $h(z)$ y la esperanza de la distribución al cuadrado de los datos muestreados, obtenemos:

$$\begin{aligned} \text{Var}(h(z)) &= E[h^2(z)] - E[h(z)]^2 = E[9x^2z^2] - \left(\frac{3z}{2}\right)^2 \\ \Rightarrow \text{Var}(h(z)) &= 9z^2 E[x^2] - \frac{9z^2}{4} = \frac{3z^2}{4} \end{aligned}$$

P1.5. Relación entre $E(h, z)$ con el sesgo y varianza en z . Cálculo de estos 3 términos con $z=1$.

Utilizando la fórmula del $E(h, z)$ para el modelo estimador $h(z)$ junto a un punto de prueba z , se observación la relación de estos 3 conceptos:

$$E(h, z) = \text{Sesgo}(z)^2 + \text{Var}(h(z))$$

Ahora obtendremos estos 3 términos reemplazando con $z = 1$ las respuestas anteriores:

$$\begin{aligned} \text{Sesgo}(z) &= \frac{-3}{2} \quad \text{Var}(h(1)) = \frac{3}{4} \\ \Rightarrow E(h, z) &= \left(\frac{-3}{2}\right)^2 + \frac{3}{4} = 3 \end{aligned}$$

P1.6. Aborde el problema de selección de características, ¿Cómo se podría mejorar el modelo?

En particular en el modelo $h(z)$ poseemos una única característica, que no es tan útil para poder estimar $g(z)$, generando una simplicidad deficiente con alto sesgo. En este sentido una forma de mejorar el modelo es mediante la reducción del sesgo, a través de agregar features no lineales como lo es z^2 , es decir: $h(z) = \theta_1 z + \theta_2 z^2$ lo cual nos permite capturar la forma real de $g(z)$.

Como otras opciones de mejora, puede ser obtener una

mayor cantidad de datos que podría estimar mejor la relación o mantener la simplicidad lineal con mas variables de entrada que capturen la no linealidad mediante transformaciones.

P1.7. Fenómeno modelable y consideraciones prácticas

Esta función cuadrática $g(z)$ que se intenta estimar puede asociarse a fenómenos reales donde la relación entre variables presenta un comportamiento no lineal, como lo es el crecimiento acelerado o fenomenos físicos(energía cinética en función de la velocidad).

Ante esta limitación la regresión lineal puede aportar **simplicidad, interpretabilidad y bajo costo computacional**, lo cual puede ser útil si el objetivo no es capturar perfectamente la relación, sino obtener una representación simple o una tendencia general. Estas mismas forman partes de consideraciones que se debe tener al momento de preferir un sistema lineal para un problema complejo, también otros motivos puede ser la disponibilidad de datos y la generalización.

P2. Regresión Lineal Bayesiana

P2.1. Demostrar que el MAP es equivalente al EMV con prior constante.

Partiendo por la definición del máximo a posteriori(MAP), se desarrollará su formulación mediante teoremas y el uso de la proporcional($\propto$), gracias a que se trabaja con la función argumento máximo. Entonces:

$$\begin{aligned}\hat{\theta}_{MAP} &= \arg \max_{\theta} p(\theta | D) && \text{/Definición} \\ &= \arg \max_{\theta} \frac{p(D | \theta) p(\theta)}{p(D)} && \text{/Teo de Bayes} \\ &\propto \arg \max_{\theta} p(D | \theta) p(\theta) && \text{/}p(D) \text{ no afecta} \\ &\propto \arg \max_{\theta} p(D | \theta) && \text{/}p(\theta) \text{ no afecta}\end{aligned}$$

donde en particular la no dependencia de $p(X)$ y $p(\theta)$ con θ , el primero por definición y el segundo por enunciado (prior constante uniforme), permite obtener un resultado proporcional que define el estimador MAP:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(D | \theta) = \arg \max_{\theta} L(\theta | D) = \hat{\theta}_{MLE}$$

donde $L()$ es la función de verosimilitud y D los datos observados, concluyendo con la demostración.

P2.2. Encuentre el estimador MAP. Identifique a qué estimador conocido corresponde.

Considerando la nueva información del prior no uniforme, la definición del estimador MAP que se trabajará es:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(D | \theta) p(\theta)$$

Por conveniencia y eficacia, la definición anterior es equivalente a trabajar con logaritmos debido a la función $\arg \max()$, por ende:

$$\begin{aligned}\hat{\theta}_{MAP} &= \arg \max_{\theta} [\log p(D | \theta) p(\theta)] \\ &= \arg \max_{\theta} [\log p(D | \theta) + \log p(\theta)]\end{aligned}$$

Ahora se buscará obtener las probabilidades necesarias para la resolución. Por enunciado el modelo lineal posee un error Gaussiano, esto provoca que: $Y | X \sim \mathcal{N}(\beta_0 + \beta^T X, \sigma^2)$, es decir la distribución condicional del objetivo es gaussiano. Llevándolo a un dato en particular (x_i, y_i) se refleja como: $y_i | x_i, \theta \sim \mathcal{N}(\beta_0 + \beta^T x_i, \sigma^2)$, es decir su densidad es:

$$p(y_i | x_i, \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta^T x_i)^2}{2\sigma^2}\right)$$

A partir de estas nociones y la independencia entre cada dato, se obtiene el "Likelihood" de toda la data:

$$\begin{aligned}p(D | \theta) &= \prod_{i=1}^N p(y_i | x_i, \theta) \\ &= \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta^T x_i)^2}{2\sigma^2}\right)\end{aligned}$$

Aplicando el logaritmo, y la propiedad clave de suma de logaritmos se obtiene:

$$\begin{aligned}\log p(D | \theta) &= \sum_{i=1}^N \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta^T x_i)^2}{2\sigma^2}\right) \right] \\ &= \sum_{i=1}^N \log \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2 \\ &= -\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2 + C\end{aligned}$$

Por otro lado, dado que $\beta_i \sim \mathcal{N}(0, \tau^2)$ son independientes, utilizando la misma metodología anterior, el log-prior es:

$$\log p(\theta) = -\frac{1}{2\tau^2} \sum_{i=1}^p \beta_i^2 + C$$

Con todo esto se puede resolver adecuadamente la formulación para el estimador MAP, importante notar que no se utilizará las constantes obtenidas C en cada logaritmo pues para la función $\arg \max$ no es relevante las constantes en su cálculo y es equivalente al sin uso de ellas, entonces:

$$\begin{aligned}\hat{\theta}_{MAP} &= \arg \max_{\theta} \left[\left(-\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2\right) + \left(-\frac{1}{2\tau^2} \sum_{i=1}^p \beta_i^2\right) \right] \\ &= \arg \min_{\theta} \left[\sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2 + \frac{\sigma^2}{\tau^2} \sum_{i=1}^p \beta_i^2 \right]\end{aligned}$$

donde en particular se usó la equivalencia del $\min()$ con el $\max()$ de algo negativo, y se realizó el despeje adecuado de constantes. LLamando $\lambda = \frac{\sigma^2}{\tau^2}$, y asociando $\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2$, finalmente obtenemos el valor final del estimador:

$$\theta_{MAP} = \arg \min_{\theta} \left[\sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2 + \lambda \|\beta\|_2^2 \right]$$

donde este estimador corresponde exactamente a "Ridge Regression", que introduce una penalización L_2 sobre los coeficientes.

P2.3. Casos con $\tau \rightarrow \infty$ y $\tau \rightarrow 0$

Recordando la definición $\lambda = \frac{\sigma^2}{\tau^2}$, veamos cada caso.

Caso $\tau \rightarrow \infty$:

Claramente $\lambda \rightarrow 0$ por lo que el término de regularización ($\|\beta\|_2^2$) desaparece, esto causa la siguiente relacion:

$$\theta_{MAP} = \arg \min_{\theta} \sum_{i=1}^N (y_i - \beta_0 - \beta^T x_i)^2 = \theta_{MLE}$$

por ende converge en el estimador de máxima verosimilitud, es decir al de minimo cuadrados ordinarios.

Con respecto a la perspectiva bayesiana donde se sabe que $\beta_i \sim \mathcal{N}(0, \tau^2 \rightarrow \infty)$, en este caso la densidad del prior se vuelve uniforme sobre toda la recta real, provocando que se vuelva cada vez más plano, lo cual refleja ausencia de información previa sobre los parámetros.

Este caso no es estrictamente alcanzable en la práctica, ya que implicaría una varianza infinita del prior, pero puede interpretarse como una aproximación a un prior no informativo, donde la influencia del conocimiento previo es despreciable. Usar τ bastante grandes permite aproximar este comportamiento y dar estimaciones dominadas por los datos.

Caso $\tau \rightarrow 0$:

Primeramente $\lambda \rightarrow \infty$, por lo que la penalización sobre los coeficientes domina el problema de optimización (el error de ajuste no influye en $\arg \min$), Como consecuencia, los coeficientes β_i tienden a cero para cumplir con la optimización, resultando en un modelo que depende únicamente del intercepto, pues este no es afectado.

Desde el punto de vista Bayesiano $\beta_i \sim \mathcal{N}(0, \tau^2 \rightarrow 0)$, el prior se concentra fuertemente en cero, lo que implica una creencia extremadamente fuerte de que los coeficientes son nulos.

Este caso no es realista en la práctica, ya que implica certeza absoluta sobre los parámetros. Pero en caso no tan exagerados, si se usan valores pequeños de τ pues implican regularización fuerte, útil cuando hay muchas variables irrelevantes.

P2.4. Demostración estimador es insesgado ssi $\rho = 0$.

Discuta si es posible. ($\rho = \lambda$)

Primero es necesario saber la expresión cerrada del estimador MAP, para eso a partir del resultado obtenido en (b):

$$\hat{\beta}_{MAP} = \arg \min_{\beta} [\|y - X\beta\|_2^2 + \rho \|\beta\|_2^2]$$

se resuelve el problema de optimización mediante la derivación respecto a β e igualar a 0 (condición de primer orden), con esto se obtiene una ecuación matricial cuya solución corresponde a :

$$\hat{\beta}_{MAP} = (X^T X + \rho I)^{-1} X^T y$$

la cuál corresponde a una demostración vista en clases, y representa el estimador de "Ridge Regression".

Antes de proseguir, por enunciado se sabe que:

$$y = X\beta + \epsilon, \quad \mathbb{E}[\epsilon] = 0 \rightarrow \mathbb{E}[y|X] = X\beta$$

Con todo esto se puede empezar a estudiar la demostración. Importante mencionar que para evaluar insesgamiento se condiciona en la matriz de diseño X pues el modelo de regresión especifica la distribución de Y dado X . Entonces:

$$\begin{aligned} E[\hat{\beta}_{MAP}|X] &= E[(X^T X + \rho I)^{-1} X^T y|X] \quad / \text{Def. estimador MAP} \\ &= (X^T X + \rho I)^{-1} X^T E[y|X] \quad / E[] \text{ excluye } X \text{ fijos} \\ &= (X^T X + \rho I)^{-1} X^T X \beta \quad / \text{Modelo gaussiano} \end{aligned}$$

Aplicando la condición de insesgamiento se evidencia que:

$$\begin{aligned} \text{Inssegamiento} &\Leftrightarrow E[\hat{\beta}_{MAP}|X] = \beta \\ &\Leftrightarrow (X^T X + \rho I)^{-1} X^T X \beta = \beta \\ &\Leftrightarrow (X^T X + \rho I)^{-1} X^T X = I \quad / \text{M. Identidad} \\ &\Leftrightarrow X^T X = X^T X + \rho I \quad / (X^T X + \rho I)^* \\ &\Leftrightarrow 0 = \rho I \quad / -X^T X \\ &\Leftrightarrow 0 = \rho \end{aligned}$$

donde a partir de la definición de operaciones de matrices con la matriz identidad, la existencia de invertibilidad y que la identidad es una matriz no nula entonces, se demuestra que el estimador es insesgado ssi $\rho = 0$.

Este caso es perfectamente posible en la práctica, ya que corresponde a no aplicar regularización, es decir, al uso del estimador de mínimos cuadrados ordinarios. Sin embargo, aunque este estimador es insesgado, puede presentar alta varianza en presencia de multicolinealidad o datos ruidosos. Por esa razón no es recomendable su uso.

Un caso práctico donde se utiliza es en problemas de regresión con pocas variables y baja correlación entre ellas, por ejemplo, al predecir el consumo de combustible de un vehículo en función de variables como peso, tamaño del motor y velocidad promedio. Con esto se presentará insesgamiento y una fácil interpretación, pero en casos donde

variables explicativas están altamente correlacionadas o el número de predictores es grande, el uso de $\rho = 0$ puede generar estimaciones inestables y con alta varianza.

P3. Regresión Lineal Caso Aplicado

Tras aplicar la selección de datos al azar con el rut personal, se obtuvo una cantidad de 6500 datos(filas) junto a 10 variables(columnas), donde estas últimas son:

- **rating** → calificación de la reseña (1 a 5)
- **title** → título de la reseña
- **text** → comentario completo del usuario
- **images** → imágenes asociadas (casi siempre vacía)
- **asin** → ID del producto en Amazon
- **parent_asin** → ID del producto “padre” (variantes)
- **user_id** → ID del usuario
- **timestamp** → fecha y hora de la reseña
- **helpful_vote** → cuántas personas encontraron útil la reseña
- **verified_purchase** → booleano que determina si la compra fue verificada

P3.1. Implementar clase LinearRegression.

Se utiliza numpy para la creación de la clase. A partir de ella se podrá estimar los parámetros del modelo mediante el método de Mínimos Cuadrados Ordinarios (MCO). Para esto es necesario crear las funciones pedidas.

Para estimar los parámetros $\hat{\theta}$, se utilizó la solución cerrada de mínimos cuadrados:

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

Antes de aplicar esta fórmula, se agregó una columna de unos a la matriz de diseño X , lo que permite incorporar el intercepto θ_0 dentro de la misma formulación matricial. Luego de esto se procedió al uso de la fórmula.

Una vez estimados los parámetros, las predicciones se realizan mediante:

$$\hat{y} = X \hat{\theta}$$

Esto corresponde simplemente a evaluar el modelo lineal utilizando los parámetros obtenidos, donde cada predicción es una combinación lineal de las variables de entrada.

P3.2. Distribución del rating en el conjunto de datos.

El gráfico obtenido con la información base fue el siguiente:




Figure 1. Histograma del Rating en el dataset según rut personal

A partir del histograma obtenido, se observa que la distribución de las calificaciones está fuertemente concentrada en valores altos, particularmente en 4 y 5 estrellas. En cambio las calificaciones bajas aparecen con menor frecuencia. Es por esto que el rating posee una distribución con asimetría hacia la izquierda (left-skewed), ya que la mayor parte de los datos se concentra en valores altos, con una cola hacia valores más bajos.

El **promedio de las calificaciones es 4.24**, lo que confirma la predominancia de opiniones positivas en el conjunto de datos. Por otro lado, **la varianza es 1.65**, lo que indica que existe cierta dispersión, aunque los valores tienden a agruparse en torno a calificaciones altas.

No es esperable que el modelo de regresión lineal tenga un buen ajuste debido a que la variable objetivo *rating* es discreta y acotada, mientras que el modelo de regresión asume por naturaleza una variable continua, lo cual causa fallas en el ajuste y da la posibilidad de resultados incompatibles como predicciones fuera del rango válido. Además la distribución está sesgada hacia valores altos, lo que puede dificultar que el modelo capture adecuadamente la variabilidad en las calificaciones más bajas. Aún así puede ser útil su uso para una primera aproximación.

P3.3. Entrenamiento del 80% del dataset e indicadores para el dataset completo

Se dividió el conjunto de datos en un 80% para entrenamiento y un 20% para prueba, con el objetivo de evaluar la capacidad de generalización del modelo. Luego se entrenó el modelo de regresión lineal implementado mediante mínimos cuadrados ordinarios.

Los parámetros estimados obtenidos son:

$$(\theta_0, \theta_1, \theta_2, \theta_3) = (4.184, 0.129, -0.000315, -0.001215)$$

donde:

- $\theta_0 = 4.184$: corresponde al intercepto del modelo, indicando que, en promedio, la calificación base es cercana a 4.18★ cuando las demás variables son 0.
- $\theta_1 = 0.129$ (*verified_purchase*): indica que las reseñas asociadas a compras verificadas tienden, en promedio, a tener una calificación aproximadamente 0.13 estrellas mayor que aquellas no verificadas.
- $\theta_2 = -0.000315$ (*helpful_vote*): muestra un efecto negativo muy pequeño, lo que sugiere que el número de votos útiles tiene una influencia prácticamente nula sobre la calificación.
- $\theta_3 = -0.001215$ (*length_of_review*): indica que reseñas más largas tienden, marginalmente, a asociarse con calificaciones ligeramente menores, aunque el efecto es muy pequeño.

Luego se evaluó el desempeño del modelo utilizando diversas métricas tanto en el conjunto de entrenamiento como en el de prueba, obteniendo así:

Métrica	Entrenamiento	Test
ECM	1.641	1.635
RMSE	1.281	1.279
MAE	0.997	0.994
R^2	0.0065	0.0095

Table 1. Métricas de desempeño del modelo

Se observa que las métricas obtenidas en ambos modelos son muy similares, lo que indica que el modelo no presenta sobreajuste y generaliza de manera consistente.

Sin embargo, el valor del coeficiente de determinación R^2 es extremadamente bajo, lo que implica que el modelo explica una fracción muy pequeña de la variabilidad en las calificaciones. Es decir, las variables consideradas tienen un poder explicativo limitado sobre la variable objetivo.

Para validar más la idea, los valores de error son relativamente altos considerando que la variable *rating* toma valores entre 1 y 5, lo que refuerza la idea de que el modelo no logra capturar adecuadamente el comportamiento de los datos.

P3.4. Implementación de Lasso y Ridge Regression

Se implementaron los modelos de Ridge y Lasso, evaluando su funcionamiento según el hiperparámetro de regularización λ . Se analizaron tanto el error cuadrático medio como la norma de los coeficientes para distintos valores de λ , en escala logarítmica para obtener una mayor globalización de los datos.




Figure 2. Comportamiento del EMC(MSE) según λ

A partir de este grafo se observa que:

- Para valores pequeños de λ , tanto Ridge como Lasso presentan un desempeño muy similar al modelo de MCO, con errores prácticamente constantes.
- En el caso de Ridge, el ECM se mantiene constante tanto en el entrenamiento como en el test incluso para valores grandes de λ . Esto significa que la regularización L_2 no está afectando significativamente el desempeño del modelo.
- Para Lasso, el error en entrenamiento y test comienza a aumentar a partir de cierto valor de λ (aproximadamente 10^{-2} en adelante), evidenciando una pérdida de capacidad predictiva debido a una regularización excesiva.

En síntesis, no existe un problema importante de sobreajuste, por lo que la regularización no mejora el desempeño, sino que en el caso de Lasso incluso lo empeora.




Figure 3. Comportamiento de la Norma segun λ

Algunos hallazgos que se observan son:

- En Ridge, la norma de los coeficientes disminuye muy levemente a medida que aumenta λ , y es prácticamente constante. Esto indica que los coeficientes no son fuertemente penalizados.
- En Lasso, la norma de los coeficientes disminuye drásticamente y se hace prácticamente cero para valores de λ mayores a 10^{-2} , dejando un modelo prácticamente constante (solo el intercepto)..

Entonces, se puede afirmar que las variables utilizadas tienen muy bajo poder explicativo. Lo que ocasiona que Lasso proceda a eliminarlas pues presentan baja utilidad. En cambio, Ridge, al no forzar coeficientes a cero, mantiene todas las variables pero con impacto reducido.

La velocidad de Lasso al eliminar se debe a la naturaleza de la penalización L_1 , que favorece soluciones con coeficientes exactamente iguales a cero. En cambio, la penalización L_2 (Ridge) solo reduce la magnitud de los coeficientes sin anularlos.

Finalmente los hallazgos que se observan en comparación al modelo MCO, son que Ridge presenta resultados prácticamente idénticos, tanto en entrenamiento como en test, lo que indica que la regularización no es necesaria en este caso. En cambio, Lasso muestra un aumento en el MSE a medida que aumenta λ , especialmente en el conjunto de test.

En síntesis, la regularización no aporta mejoras en términos de generalización lo que indica que el modelo base ya presenta un sesgo alto y una baja capacidad predictiva, más que un problema de *overfitting*.

P3.5. Análisis de la matriz de correlaciones.

A partir de las variables predictoras seleccionadas se calculó la matriz de correlaciones de Pearson. Los resultados se muestran en la siguiente visual:




Figure 4. Correlación de variables predictoras

La principal interpretación de las correlaciones son:

- La correlación entre *verified_purchase* y *helpful_vote* es prácticamente nula (-0.017), indicando que no existe una relación lineal entre ambas.
- La correlación entre *verified_purchase* y *length_of_review* es **débilmente** negativa (-0.237), lo que sugiere que las reseñas verificadas tienden a ser ligeramente más cortas.
- La correlación entre *helpful_vote* y *length_of_review* es **débilmente** positiva (0.183), indicando que reseñas más extensas reciben en promedio un poco más de votos de utilidad.

Con lo anterior se puede afirmar que no existe multicolinealidad significativa. Esta ocurre cuando dos o más predictores están en rangos entre 0.7 o 0.8. En este caso, todos los coeficientes de correlación son cercanos a cero, por ende no es suficiente para garantizar multicolinealidad. Por lo tanto cada predictor aporta información relativamente única.

Si existiera multicolinealidad alta en MCO se producirían problemas de alta varianza en los coeficientes estimados, errores estándar inflados e interpretaciones engañosas (signos contrarios o magnitud irreales).

Ridge y Lasso mitigan la multicolinealidad al agregar una penalización que estabiliza los coeficientes. Ridge encoge

todos los coeficientes sin eliminarlos, reduciendo la varianza. Lasso, además, puede anular coeficientes de variables redundantes, eliminando la dependencia lineal entre ellas.

P3.6. Análisis con escalado a los datos.

Aplicando una estandarización a las variables predictoras utilizando `StandardScaler`, tal que cada variable tenga media cero y varianza uno. Este procedimiento se realizó ajustando el escalador únicamente sobre el conjunto de entrenamiento, para evitar filtración de información hacia el conjunto de prueba.

Las métricas obtenidas antes y después del escalamiento son directamente comparables ya que la variable objetivo (*rating*) no fue transformada. Por lo tanto, medidas como *MSE*, *RMSE*, *MAE* y R^2 se mantienen en la misma escala. Los resultados obtenidos fueron:

Métrica	Entrenamiento	Test
MSE	1.641	1.635
RMSE	1.281	1.279
MAE	0.997	0.994
R^2	0.0065	0.0095

Table 2. Métricas de desempeño del modelo

donde se evidencia que los valores son prácticamente idénticos a los obtenidos sin escalamiento.

Tras el escalamiento los coeficientes del modelo cambian en magnitud, ya que ahora todas las variables se encuentran en la misma escala. En base a esto cada parámetro representa el efecto de un cambio de una desviación estándar en la variable correspondiente, permitiendo una mejor comparación relativa entre los coeficientes.

Se puede notar que el impacto en los modelos es bastante pequeño, por ejemplo en MCO, el escalamiento no afecta el desempeño predictivo, como se observa en las métricas, que permanecen prácticamente iguales. Esto se debe a que la regresión lineal es invariante ante transformaciones lineales de las variables. Ridge y Lasso son prácticamente iguales al sin escalonamiento.

Con respecto a las diferencias entre entrenamiento y test, al igual que en los casos anteriores, las métricas son muy similares lo que indica que el modelo no presenta sobreajuste. Esto sugiere que el problema principal no es la varianza del modelo, sino su capacidad limitada para capturar la relación entre las variables.

P3.7. Inserción de nuevas variables

Se incorporaron dos nuevas variables al modelo: el mes y el año de publicación de cada reseña. El objetivo es evaluar si existe algún patrón temporal que permita mejorar la predicción de las calificaciones.

No es esperable que aporten ya que la calificación de una

reseña depende principalmente de la experiencia del usuario con el producto. Variables como el mes o el año no tienen una relación directa con la calidad del producto o la satisfacción del cliente. A continuación se muestran los nuevos resultados obtenidos:

Modelo	Conjunto	MSE	RMSE	MAE	R^2
MCO	Train	1.638	1.280	0.998	0.0085
	Test	1.631	1.277	0.994	0.0123
Ridge	Train	1.638	1.280	0.998	0.0085
	Test	1.631	1.277	0.994	0.0123
Lasso	Train	1.638	1.280	0.999	0.0082
	Test	1.632	1.277	0.994	0.0114
ElasticNet	Train	1.638	1.280	0.998	0.0084
	Test	1.631	1.277	0.994	0.0119

Table 3. Comparación de métricas entre modelos

Algunos hallazgos relevantes que se visualizan son:

- Las métricas son muy similares entre todos los modelos, sin diferencias relevantes entre MCO, Ridge, Lasso y ElasticNet.
- Los valores de R^2 siguen siendo muy bajos lo que indica que el modelo explica una fracción muy pequeña de la variabilidad en las calificaciones.
- Las métricas en entrenamiento y test son prácticamente iguales, lo que indica que no existe sobreajuste.

Con esto en mente, se puede afirmar que la incorporación de las variables temporales no mejora sustancialmente el desempeño del modelo, lo que sugiere nuevamente que el problema sigue estando dominado por la falta de variables relevantes.

Algunas limitaciones son que las variables temporales no capturan factores relevantes como calidad del producto o experiencia del usuario, además que este tipo de variables son una representación muy simplificada del contexto. Por último que también puede sonar interesante es que el modelo sigue siendo lineal, lo que limita su capacidad para capturar relaciones complejas.

En síntesis no se genera mejoras significativas en el desempeño del modelo.

P3.8. Recomendación del mejor modelo

A partir de los resultados obtenidos, el método de MCO es de las mejores opciones para modelar este problema, pues:

- Presenta un desempeño prácticamente idéntico a Ridge, Lasso y ElasticNet en todas las métricas evaluadas.
- Es el modelo más simple e interpretable.

- No requiere la selección de hiperparámetros adicionales como ocurre en los métodos regularizados.

Básicamente como la regularización no mejora el desempeño, no es necesario el uso de un sistema sofisticado y complejo.

Con respecto a la métrica mas robusta, el MAE es el que presenta mejor esta peculiaridad debido a que no penaliza de forma cuadrática los errores grandes, a diferencia del MSE o RMSE, y además es menos sensible a valores atípicos. Otro argumento que suma es que la distribución de las calificaciones al ser sesgada, el MAE proporciona una medida más estable del error promedio.

Hablando sobre la conexión con la P2, desde el punto de vista Bayesiano, los métodos de regularización pueden interpretarse como estimadores MAP:

- Ridge Regression equivale a asumir un prior gaussiano sobre los coeficientes: $\beta_i \sim \mathcal{N}(0, \tau^2)$
- Lasso Regression equivale a asumir un prior Laplaciano: $\beta_i \sim \text{Laplace}(0, b)$

En ambos casos la regularización introduce una penalización que refleja una creencia previa de que los coeficientes deben ser pequeños.

Finalmente la distribución posterior combina el prior con los datos observados; en este caso, como los datos tienen bajo poder explicativo, el prior domina la estimación de los parámetros. Por eso métodos como Lasso tienden a llevar coeficientes a 0, favoreciendo soluciones más simples cuando la evidencia en los datos es débil.

References

Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.