

Tarea 2

Fecha de entrega: 27 de abril, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Álvaro Márquez, Diego Olguín Wende

Ayudantes: Tamara Carrasco, Javiera Yáñez

Formato de entrega	PDF con extensión máxima de 8 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1 (30 %) - Inferencia Bayesiana: Modelo Beta-Bernoulli

Considere un experimento donde se lanza una moneda (potencialmente sesgada) n veces de forma independiente. Sea $X_i \sim \text{Bernoulli}(\theta)$ i.i.d., donde $\theta \in [0, 1]$ es la probabilidad de obtener cara (éxito). Bajo el enfoque Bayesiano, asumimos un prior sobre el parámetro θ dado por una distribución Beta:

$$\theta \sim \text{Beta}(\alpha, \beta), \quad p(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}.$$

- (2 pts) Suponga que se observan n lanzamientos y se obtienen s caras ($s = \sum_{i=1}^n X_i$). Derive la distribución posterior $p(\theta \mid \mathcal{D}_n)$. Identifique la familia y los parámetros de la posterior. Explique por qué la distribución Beta es llamada un *prior conjugado* para la verosimilitud Bernoulli. Calcule el estimador puntual Bayesiano (media posterior) y el estimador de máxima verosimilitud (MLE). Compare ambos estimadores: ¿bajo qué condiciones coinciden?
- (1.5 pts) Derive la distribución predictiva $\mathbb{P}(X_{n+1} = 1 \mid \mathcal{D}_n)$. Relacione este resultado con la regla de sucesión de Laplace. Además, obtenga el estimador MAP (máximo a posteriori) de θ . Muestre que el MAP puede escribirse como una combinación convexa entre el MLE y la moda del prior. ¿Qué ocurre con el MAP cuando $\alpha = \beta = 1$ (prior uniforme)? ¿Y cuando $\alpha, \beta < 1$? ¿Está el MAP siempre bien definido?

3. (2.5 ptos) Utilice su RUT (sin dígito verificador) como semilla aleatoria. Genere $n = 1000$ observaciones de una Bernoulli($\theta_{\text{true}} = 0.7$). Para los siguientes cuatro priors:

- Beta(1, 1) (uniforme, no informativo),
- Beta(5, 1) (optimista, cree que θ es alto),
- Beta(1, 5) (pesimista, cree que θ es bajo),
- Beta(10, 10) (creencia fuerte en $\theta = 0.5$),

grafique las distribuciones posteriores tras observar $k = 1, 5, 10, 25, 50, 100, 500, 1000$ datos, para cada uno de los cuatro priors. Grafique la evolución de la media posterior, el MAP, y un intervalo de credibilidad del 95 % en función de k , para cada prior. Incluya además la evolución del MLE como referencia. ¿A partir de qué tamaño muestral (aproximadamente) la elección del prior se vuelve despreciable? Discuta el concepto de consistencia Bayesiana. ¿Convergen el MAP y la media posterior al mismo valor? ¿Por qué?

4. (1 pto) Explique la distinción entre incertidumbre aleatoria e incertidumbre epistémica en el contexto de este experimento. ¿Cómo se manifiesta cada tipo en las distribuciones posteriores obtenidas? ¿En qué se diferencia la distribución predictiva Bayesiana de una predicción *plug-in* que simplemente utilice el MLE? Comente.

P2 (70 %) - Regresión no lineal y MLE

En el archivo `data_t2_p2.json` se encuentran los datos de la cantidad de reseñas de una categoría de productos en Amazon, extraídos del dataset público *Amazon Reviews 2023*¹, registrados entre enero 2009 y junio 2023. El archivo contiene tres niveles de agregación temporal:

- **daily**: conteo de reseñas por día (5294 registros),
- **weekly**: conteo de reseñas por semana (757 registros),
- **monthly**: conteo de reseñas por mes (174 registros).

Cada registro incluye un índice temporal, la(s) fecha(s) correspondiente(s) y el conteo de reseñas. El estudiante debe elegir la granularidad que considere más adecuada para el análisis y justificar su elección. Los datos son de la forma $\{(x_i, y_i)\}_{i=1}^n$, donde x_i representa un índice temporal e y_i la cantidad de reseñas en el período correspondiente.

El objetivo de esta pregunta es modelar la cantidad de reseñas (y) respecto al tiempo (x). Para esto, se asumirá el siguiente modelo:

$$y = f_{\theta}(x) + \eta,$$

donde θ son los parámetros de la función f que se deben ajustar, y $\eta \sim \mathcal{N}(0, \sigma_n^2)$ es ruido gaussiano.

Separe los datos en un conjunto de entrenamiento y otro de test. Considere que el 75 % de los datos son para entrenar (primeros datos cronológicamente) y el 25 % restante es de test.

1. (1 pto) Cargue los datos y explore las tres granularidades disponibles. Grafique al menos dos de ellas y seleccione la que considere más adecuada para el modelo propuesto. Justifique su elección considerando la relación señal-ruido, la cantidad de datos y la estructura temporal observable.

¹ Hou, Y., et al. (2024). *Bridging Language and Items for Retrieval and Recommendation*. Disponible en <https://amazon-reviews-2023.github.io/>.

Luego, usando la granularidad elegida, grafique los datos separando los conjuntos de entrenamiento y test de forma que sean fácilmente identificables. Describa los patrones observables: ¿hay tendencia?, ¿estacionalidad?, ¿cambios de amplitud a lo largo del tiempo?

2. (0.5 ptos) Utilice la función **polyfit** de **numpy** para ajustar un modelo polinomial de grado 1, 2, 3, 4, 5 con los datos de entrenamiento. Grafique las curvas obtenidas y su ajuste a los datos de test.
3. (1 pto) Reporte el Error Cuadrático Medio (ECM), el Error Absoluto Medio (EAM), el Coeficiente de Determinación (R^2) y el Error Cuadrático Logarítmico Medio (MSLE). ¿Qué puede decir respecto de los distintos valores que se obtienen de las métricas? ¿Qué métrica considera usted que sería mejor para este caso? ¿Qué comportamiento ocurre con cada una de las curvas ajustadas? ¿Qué es lo esperable cuando x crece? Lo anterior debe ser observado en los datos de test. Seleccione el mejor grado polinomial y justifique su elección.

Indicación: Observe que los datos corresponden a conteos (números enteros no negativos). Algunos períodos tempranos presentan valores muy cercanos a cero. Para el cálculo del MSLE utilice $\log(1 + y)$ en lugar de $\log(y)$.

4. (1 pto) Formule el modelo probabilístico explícitamente: escriba la log-verosimilitud $\ell(\theta)$ del modelo gaussiano y demuestre que maximizar la log-verosimilitud respecto a los parámetros polinomiales es equivalente a minimizar la suma de errores cuadrados, es decir, que el estimador MLE coincide con el estimador de mínimos cuadrados ordinarios (MCO) para este modelo.

Como podrá observar, no es posible capturar el movimiento periódico de los datos usando sólo un polinomio. Denotemos por f^{pol} al mejor polinomio encontrado en la parte anterior. Modelaremos la señal con el siguiente modelo:

$$y = f^{\text{pol}}(x) + \theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x} + \eta,$$

con $\eta \sim \mathcal{N}(0, \sigma_n^2)$.

5. (2 ptos) Ajuste $\theta_1, \theta_2, \theta_3, \theta_4$ usando máxima verosimilitud. Note que este modelo no es lineal en los parámetros, por lo que no se puede escribir una solución de forma exacta. Para encontrar los parámetros de máxima verosimilitud, construya la función de verosimilitud y optimice utilizando la función **minimize** de **scipy.optimize** usando el método BFGS. ¿Qué tan bueno es el ajuste encontrado? Reporte las métricas ECM, EAM, R^2 y MSLE. ¿Por qué no es posible obtener una solución cerrada para el MLE en este caso, a diferencia del ajuste polinomial? Explore distintos valores iniciales para θ y discuta la sensibilidad de la optimización a las condiciones iniciales.

Indicación: Puede ser útil ocupar $\theta_4 = 0.01$ como condición inicial.

El comportamiento de los datos no es sólo sinusoidal, por lo que agregaremos una última componente. Denotemos por $f^{\text{pol-sin}}$ a la función f_θ encontrada en la parte anterior. Agregue una segunda componente sinusoidal modulada por una exponencial al modelo, es decir:

$$y = f_\theta + \eta = f^{\text{pol-sin}}(x) + \theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x} + \eta.$$

6. (2 ptos) Considere los parámetros de $f^{\text{pol-sin}}$ fijos e iguales a su resultado de la parte anterior. Nuevamente use máxima verosimilitud para encontrar $\theta_5, \theta_6, \theta_7, \theta_8$. En esta ocasión, utilice **minimize** de **scipy.optimize** variando el método de optimización: compare al menos **BFGS**, **Nelder-Mead** y **L-BFGS-B**. Evalúe su solución prediciendo el 25 % restante de los datos. Reporte las métricas

ECM, EAM, R^2 y MSLE. ¿Convergen todos los métodos a la misma solución? ¿Qué diferencias observa en términos de número de iteraciones, evaluaciones de función y calidad del resultado?

Indicación: Nuevamente, puede ser útil ocupar $\theta_8 = 0.01$ como condición inicial.

7. (1.5 pts) Presente sus resultados y discuta el método con el que los obtuvo, en particular:

- Explique el rol de cada una de las componentes del modelo final (polinomio, primera componente sinusoidal, segunda componente sinusoidal). ¿Cuál captura la tendencia? ¿Cuál captura la estacionalidad?
- ¿Habría sido posible entrenar el modelo final de una vez, es decir, optimizar todos los parámetros simultáneamente? ¿Qué dificultades prácticas tendría esto?
- Evalúe los modelos ajustados en función de su verosimilitud y del error de predicción en el conjunto de evaluación. En la parte 4 usted demostró que, bajo ruido gaussiano, maximizar la verosimilitud equivale a minimizar el ECM. ¿Se sigue cumpliendo esta equivalencia cuando el modelo no es lineal en los parámetros? ¿En qué situaciones dejarían de ser equivalentes?
- Compare los métodos de optimización utilizados (BFGS, Nelder-Mead, L-BFGS-B). ¿Cuáles son las diferencias fundamentales entre un método basado en gradiente y uno libre de derivadas? ¿Cuándo podría preferirse uno sobre otro?

8. (2 pts) **Análisis crítico del modelo y los datos.**

- El modelo asume ruido gaussiano con varianza constante σ_n^2 . Obtenga el estimador de máxima verosimilitud de σ_n^2 a partir de su modelo final. Luego, grafique los residuos $r_i = y_i - \hat{f}_{\hat{\theta}}(x_i)$ en función del tiempo y en función de los valores predichos $\hat{y}_i$. ¿Se mantiene la hipótesis de varianza constante? Comente si observa heterocedasticidad.
- Los datos corresponden a conteos de reseñas (valores enteros no negativos), pero el modelo utiliza ruido gaussiano continuo. ¿Es razonable este supuesto? ¿Qué distribución alternativa podría ser más apropiada para modelar datos de conteo? Discuta brevemente.
- Observe los residuos cuidadosamente. ¿Identifica algún período donde el modelo falla de forma sistemática? ¿Podría haber algún cambio estructural o evento externo que afecte el patrón de los datos? ¿Cómo maneja el modelo este tipo de quiebres? ¿Qué consecuencias tiene para la predicción en el conjunto de test?
- ¿Cómo podría incorporar la incertidumbre epistémica (estudiada en P1) a las predicciones de este modelo de regresión? Describa conceptualmente cómo el enfoque Bayesiano permitiría obtener bandas de confianza para las predicciones, en lugar de una predicción puntual.