
Tarea 2

Magíster en Ciencia de Datos

Autor: Matias CColque Antachoque¹ Profesor: Francisco Vásquez L.¹

Abstract

Se estudia un modelo Beta-Bernoulli bajo inferencia bayesiana, derivando la posterior y los estimadores, y se modela una serie temporal de reseñas de Amazon mediante regresión no lineal con componentes polinomiales y sinusoidales. Los resultados muestran consistencia bayesiana y limitaciones en la extrapolación de modelos complejos.

P1. Inferencia Bayesiana

P1.1. Identificar $p(\theta|D_n)$. Explicar prior conjugado. Calcular EPB y EMV

Primeramente debemos definir uno de los componentes de la posterior, la verosimilitud $P(D_n|\theta)$. Para eso se utiliza la distribución conocida de Bernoulli, mediante el uso de la variable binaria X_i junto a la probabilidad θ , como también la propiedad de i.i.d entre los datos de ella, obteniendo así:

$$p(D_n | \theta) = \prod_{i=1}^n \theta^{X_i} (1 - \theta)^{1-X_i} = \theta^s (1 - \theta)^{n-s}$$

Con esto se puede proceder a obtener la posterior, para eso usando bayes:

$$\begin{aligned} p(\theta|D_n) &= \frac{p(D_n|\theta)p(\theta)}{p(D_n)} && / \text{Bayes} \\ &\propto p(D_n|\theta)p(\theta) && / D_n \text{ no afecta a } \theta \\ &\propto \theta^{s+\alpha-1} (1 - \theta)^{n-s+\beta-1} && / \Gamma \text{ no afecta a } \theta \end{aligned}$$

Se puede reconocer el **núcleo de una distribución Beta**, más allá que no aparezcan los Γ convenientemente se puede hacer aparecer mediante el uso de proporcionalidad. Donde sus parámetros corresponde a $(\alpha+s)$ y $(\beta+n-s)$. Entonces:

$$\theta | D_n \sim \text{Beta}(\alpha + s, \beta + n - s)$$

^{*}Equal contribution ¹Universidad de Chile, Santiago, Chile. Correspondence to: Matias CColque A. <matias.ccolque@ug.uchile.cl>.

La distribución Beta es conjugada para la verosimilitud Bernoulli porque la posterior pertenece a la misma familia que el prior (Beta). Esto hace que la actualización sea muy simple: solo se suman éxitos y fracasos observados a los parámetros del prior.

Para la media posterior, se obtiene mediante la ecuación conocida de la esperanza de una distribución beta:

$$\hat{\theta}_{\text{Bayes}} = \mathbb{E}[\theta | D_n] = \frac{\alpha + s}{\alpha + \beta + n}$$

Con respecto al $\hat{\theta}_{EMV}$, convenientemente se trabaja con la log-verosimilitud, y se deriva respecto a θ para hallar aquel valor que la maximiza, entonces:

$$\ell(\theta) = s \log \theta + (n - s) \log(1 - \theta)$$

$$\begin{aligned} \rightarrow \frac{d\ell}{d\theta} &= \frac{s}{\theta} - \frac{n-s}{1-\theta} = 0 && / \text{Cond. Primer Orden} \\ \rightarrow \hat{\theta}_{MLE} &= \frac{s}{n} \end{aligned}$$

Podemos notar que MLE utiliza solo los datos, en cambio el Bayesiano incorpora además los parámetros del prior provocando que se “encoja” la estimación hacia la media del prior, pues $n > s$. La coincidencia se da:

$$\hat{\theta}_{\text{Bayes}} = \hat{\theta}_{MLE} \Leftrightarrow \frac{s}{n} = \frac{\alpha}{\alpha + \beta}$$

es decir, cuando la frecuencia observada coincide con la media del prior.

P1.2. Distribución predictiva, sucesión de Laplace y MAP.

La distribución predictiva refleja el cálculo de la probabilidad de que el próximo lanzamiento sea cara, considerando los datos conocidos y la incertidumbre sobre θ . Aplicando la ecuación de una distribución predictiva bayesiana:

$$P(X_{n+1} = 1 | D_n) = \int P(X_{n+1} = 1 | \theta) p(\theta | D_n) d\theta$$

como se sabe que: $P(X_{n+1} = 1 \mid \theta) = \theta$, pues es información base del modelo Bernoulli, donde el éxito es θ . Entonces:

$$P(X_{n+1} = 1 \mid D_n) = \int \theta p(\theta \mid D_n) d\theta = \mathbb{E}[\theta \mid D_n]$$

donde esta esperanza fue ya calculada anteriormente, dando como resultado:

$$P(X_{n+1} = 1 \mid D_n) = \frac{\alpha + s}{\alpha + \beta + n}$$

esto nos dice que la mejor predicción para el próximo lanzamiento es el promedio de lo que se cree sobre θ .

La regla de sucesión de Laplace utiliza un prior uniforme, como por ejemplo: $\theta \sim \text{Beta}(1, 1)$, provocando que:

$$P(X_{n+1} = 1 \mid D_n) = \frac{s + 1}{n + 2}$$

Esto nos dice que Laplace agrega un pseudo-exito y un pseudo-fracaso al momento de estimar la probabilidad al observar s éxitos en n ensayos, siendo diferente al cálculo usual de s/n . Esto sirve para evitar probabilidades extremas, por ejemplo si $s = 0$, nos indica que la probabilidad no es nula, lo mismo con $s = n$, evitando un 100% de éxito.

Con respecto al $\hat{\theta}_{MAP}$, sabiendo que la posterior sigue una distribución Beta, entonces el valor que maximiza la probabilidad de esta es la moda, pues representa el valor donde se concentra las probabilidades. Entonces:

$$\hat{\theta}_{MAP} = \text{Moda}(\theta \mid D_n) = \frac{\alpha + s - 1}{\alpha + \beta + n - 2}$$

notar que las condiciones para que funcione esto son:

$$\alpha + s > 1, \beta + n - s > 1$$

de lo contrario existen problemas de unicidad o concentración en los bordes.

Ahora para ver la relación del MAP, con los otros componentes, se recordará la definición de Moda del prior:

$$\text{moda}(\theta) = \frac{\alpha - 1}{\alpha + \beta - 2}, \quad \alpha, \beta > 1$$

Para ver como se relacionan convenientemente se reordenará los términos del MAP:

$$\hat{\theta}_{MAP} = \frac{\alpha + s - 1}{\alpha + \beta + n - 2} = \frac{(\alpha - 1) + s}{(\alpha + \beta - 2) + n}$$

Introduciendo un peso $w = \frac{n}{\alpha + \beta + n - 2}$ y su complemento $1 - w = \frac{\alpha + \beta - 2}{\alpha + \beta + n - 2}$, se obtiene:

$$\begin{aligned} \hat{\theta}_{MAP} &= w \cdot \frac{s}{n} + (1 - w) \cdot \frac{\alpha - 1}{\alpha + \beta - 2} \\ &= w \cdot \hat{\theta}_{MLE} + (1 - w) \cdot \text{moda}(\theta) \end{aligned}$$

donde $0 < w < 1$, es una combinación convexa. A partir de esto, cuando n es grande influye más el MLE y cuando los datos son pocos es más determinante el prior. Para el caso de $\alpha = 1 = \beta$, es decir un prior uniforme, nuestra variable $w = 1$, lo que genera que el componente asociado a la moda sea nulo, obteniend así: $\hat{\theta}_{MAP} = \hat{\theta}_{MLE}$.

Cuando $\alpha, \beta < 1$, la distribución Beta del prior toma forma de U, asignando mayor densidad cerca de los extremos $\theta = 0$ y $\theta = 1$, y menor densidad en valores intermedios. En consecuencia, la posterior puede conservar esa preferencia por valores extremos si la muestra es pequeña. En tales casos, el estimador MAP puede ubicarse en los bordes del intervalo, tomando valor 0 o 1, en lugar de una solución interior. Solo cuando los datos son suficientes para que los parámetros posteriores satisfagan $\alpha + s > 1$ y $\beta + n - s > 1$, aparece una moda interior dada por la fórmula usual del MAP. Esto evidencia que el MAP depende fuertemente del prior cuando el tamaño muestral es reducido.

El estimador MAP no está siempre bien definido como una solución interior única, pues si alguno de los parámetros de Beta para $\theta \mid D_n$ es menor o igual a 1, el máximo de la posterior puede ubicarse en los bordes $\theta = 0$ o $\theta = 1$, generando irregularidades. Incluso, si ambos son menores que 1, pueden existir dos máximos en los extremos, por lo que el MAP no sería único.

P1.3. Análisis de casos




Figure 1. Comparación de Posteriores con distintos k

La Figura 1 compara las distribuciones posteriores para $k = 10$ y $k = 1000$, utilizando los cuatro priors considerados.

Para $k = 10$, aún existe alta influencia del prior. Se observa que Beta(5,1), al ser optimista, desplaza la posterior hacia valores altos de θ , mientras que Beta(1,5), al ser pesimista, concentra mayor masa en valores bajos. Por su parte, Beta(10,10), al representar una creencia fuerte en torno a 0.5, genera una posterior más concentrada alrededor de valores intermedios. En contraste, Beta(1,1), al ser uniforme, produce una posterior más guiada por los datos.

observados.

A medida que se fue aumentando el valor de k estas curvas iban cerrando su anchura y aumentando su pico de altura. A partir de $k = 100$, se observó que ya estaba mucho más delgada la curva, pero aún no era suficiente para tener una predicción con exactitud, que es lo que se busca con estas investigaciones. Con $k = 500$ ya se pudo decir que continuar con más valores es despreciable, pues la curva se encontraba suficientemente delgada donde los valores giraban entorno al 0.7. Pero con $k = 1000$, con mucha certeza se garantizó el valor de la densidad de la posterior, concentrando los datos en $\theta = 0.7$, aunque esto no es tan idóneo pues se recurre a estudiar la observación total. Por esa razón tomar $k = 100$ o $k = 500$, puede conllevar relativamente a buenas predicciones.




Figure 2. Evolución del estimador para Beta(10,10)

La Figura 2 muestra la evolución de distintos estimadores utilizando el prior Beta(10,10), seleccionado por ser el prior más informativo y, por tanto, el caso donde el efecto inicial del prior es más notorio. Los demás priors presentan una dinámica análoga, aunque con menor sesgo inicial.

Se aprecia que, para valores pequeños de k , existe diferencia entre los estimadores debido al peso relativo del prior. Sin embargo, conforme aumenta el tamaño muestral, la media posterior, el MAP y el MLE convergen progresivamente hacia valores cercanos a $\theta_{true} = 0.7$. Estos resultados evidencian el concepto de consistencia Bayesiana: cuando el modelo está correctamente especificado y el tamaño muestral crece, la distribución posterior se concentra alrededor del verdadero valor del parámetro. En consecuencia, tanto la media posterior como el MAP convergen hacia θ_{true} para tamaños muestrales grandes, pues la influencia del prior desaparece frente a la evidencia acumulada.

P1.4. Incertidumbre y P.Bayesiana

En este experimento, la **incertidumbre aleatoria** corresponde a la variabilidad inherente de los lanzamientos de moneda. Es irreducible y está representada por la distribución Bernoulli del proceso generador. Por otro lado, la **incertidumbre epistémica** proviene del desconocimiento del verdadero valor de θ . Antes de observar los datos, no se conoce la probabilidad real de éxito, por lo que esta in-

certidumbre se evidencia en la distribución prior y luego mediante la posterior.

En las distribuciones posteriores obtenidas, la incertidumbre epistémica se refleja en la dispersión de la curva, con pocos datos las posteriores son anchas, mientras que con muchos datos se vuelven más concentradas alrededor del valor verdadero. Por otro lado, la incertidumbre aleatoria produce que la posterior se concentre en un valor específico, provocando que la predicción de una nueva observación siga siendo probabilística.

La distribución P. Bayesiana integra la incertidumbre sobre θ , utilizando toda la distribución posterior. En cambio, la predicción plug-in reemplaza θ por un único valor estimado, ignorando la incertidumbre paramétrica.

P2. Regresión No Lineal y MLE

P2.1. Exploración de granularidades

Se cargó el archivo entregado en formato JSON, el cual contiene la serie temporal del número de reseñas agregadas en tres niveles de granularidad. Se evidenció mediante la función *shape* que a medida que la escala de granularidad crecía, la cantidad de columnas aumentaba, entregando más información. Para el análisis inicial se visualizaron las series semanal y mensual, con el objetivo de identificar tendencias, ruido y posibles patrones temporales.




Figure 3. Comparación conteos semanal y mensual

En la granularidad semanal, la serie presenta alta variabilidad de corto plazo y oscilaciones frecuentes lo cual dificulta distinguir claramente la tendencia general. En cambio, la serie mensual suaviza gran parte de dicho ruido y permite visualizar de mejor manera la evolución del conteo en largo plazo, manteniendo al mismo tiempo información suficiente sobre cambios relevantes y comportamiento general.

Por esta razón, se seleccionó la **granularidad mensual**, pues ofrece un equilibrio adecuado entre cantidad de observaciones y estabilidad estadística, facilitando la estimación de modelos no lineales y mejorando la interpretabilidad de los resultados.

Con esta selección se definió: x = índice temporal e y = cantidad mensual de reseñas, para realizar el entrenamiento, en el cual se utiliza un 75% para entrenamiento y un 25% para testear, dejando así el valor $x = 130$ como el límite entre el train y el test.




Figure 4. Entrenamiento para Conteo Mensual

Se observa una tendencia creciente durante gran parte del conjunto de entrenamiento, seguida de una leve estabilización o descenso en el período de prueba. También existe estacionalidad, evidenciada por picos recurrentes en distintos intervalos de tiempo. La amplitud de las fluctuaciones aumenta con los años, ya que en los primeros períodos la variabilidad es baja y luego aparecen oscilaciones mucho mayores. El conjunto de entrenamiento captura los principales patrones históricos, mientras que el conjunto de prueba permite evaluar la capacidad predictiva en períodos recientes.

P2.2. Ajuste modelo polinomial




Figure 5. Entrenamiento para Conteo Mensual

Se observa que los polinomios de grado 4 y 5 generan predicciones negativas en el conjunto de test, lo cual es inadmisibles para modelar conteos de reseñas. Este comportamiento evidencia sobreajuste y mala extrapolación fuera del rango de entrenamiento. Por lo tanto, estos grados se descartan y la selección del mejor polinomio se restringirá a grados 1 o 2.

P2.3. Métricas y elección de grado

Table 1. Métricas de desempeño según grado del polinomio

Grado	ECM	EAM	R2	MSLE
1	1556828.3	1088.08	-0.81	0.74
2	3150882.8	1585.33	-2.66	1.13
3	1140189.1	781.05	-0.33	6.52
4	25497035.4	4114.14	-28.66	36.87
5	10349483.7	2690.91	-11.03	32.34

Los resultados muestran que ningún polinomio logra un buen ajuste en test, evidenciado por valores de R^2 negativos en todos los grados, lo que indica que los modelos predicen peor que simplemente usar la media de los datos. Los grados 4 y 5 presentan las peores métricas en ECM y MSLE consecuencia directa de la extrapolación divergente observada en el gráfico anterior. El grado 3 muestra el menor ECM y EAM, sin embargo su MSLE elevado revela que falla especialmente en períodos con valores bajos, produciendo predicciones negativas que se penalizan fuertemente.

Para datos de conteo con alta variabilidad relativa como estos, **el MSLE es la métrica más adecuada**, ya que penaliza proporcionalmente los errores independientemente de la magnitud.

A medida que x crece, los polinomios de grado alto divergen rápidamente fuera del rango de entrenamiento, comportamiento esperable por su naturaleza extrapolativa. Por esto se **selecciona el grado 1** como el mejor modelo, pues aunque no captura toda la estructura de los datos, es el más estable en extrapolación y obtiene el menor MSLE, lo que lo hace más confiable para predecir fuera de la muestra de entrenamiento.

P2.4. Modelo probabilístico

El modelo asume que cada observación y_i se genera como:

$$y_i = f_\theta(x_i) + \eta_i, \quad \eta_i \sim \mathcal{N}(0, \sigma_n^2)$$

donde $f_\theta(x_i) = \sum_{k=0}^d \theta_k x_i^k$ es un polinomio de grado d . La verosimilitud de una observación es:

$$p(y_i | x_i, \theta) = \frac{1}{\sqrt{2\pi\sigma_n^2}} \exp\left(-\frac{(y_i - f_\theta(x_i))^2}{2\sigma_n^2}\right)$$

Asumiendo independencia entre observaciones, la log-verosimilitud del conjunto de datos es:

$$\ell(\theta) = \sum_{i=1}^n \log p(y_i | x_i, \theta) = -\frac{n}{2} \log(2\pi\sigma_n^2) - \frac{1}{2\sigma_n^2} \sum_{i=1}^n (y_i - f_\theta(x_i))^2$$

Maximizar $\ell(\theta)$ respecto a θ es equivalente y proporcional a minimizar el único término que depende de θ , pues $-\frac{1}{2\sigma_n^2}$ es negativo, entonces $\min = -\max$ y como es una

constante puede desaparecer estudiando proporcionalidad, provocando que:

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2 = \hat{\theta}_{MCO}$$

Por lo tanto, bajo el supuesto de ruido gaussiano homocedástico, el estimador MLE coincide exactamente con el estimador de mínimos cuadrados ordinarios (MCO), independientemente del valor de σ_n^2 .

P2.5. Ajuste con Modelación N°2

Dado que el modelo no es lineal en los parámetros $(\theta_1, \theta_2, \theta_3, \theta_4)$, no existe solución cerrada para el MLE, a diferencia del caso polinomial donde la log-verosimilitud es cuadrática en θ y admite solución analítica vía mínimos cuadrados. La presencia de $\sin(\theta_2 x + \theta_3)$ y $e^{\theta_4 x}$ genera una superficie de pérdida no convexa, por lo que se requiere optimización numérica iterativa. En la siguiente figura se observa el comportamiento no convexo del ajuste:




Figure 6. Ajuste modelo nuevo no convexo

Se utilizó el método BFGS, donde se minimiza la suma de errores cuadrados. Se exploraron 5 condiciones iniciales distintas, de los cuáles los parámetros óptimos fueron los siguientes:

$$\hat{\theta} = (\theta_1, \theta_2, \theta_3, \theta_4) \approx (-344.09, 2.613, 2.322, 0.092)$$

Con respecto a la **sensibilidad a condiciones iniciales**, todos los puntos de inicio convergieron a la misma pérdida (34.233.926), lo que sugiere que el optimizador encuentra consistentemente el mismo mínimo local. Sin embargo, ninguna iteración reportó `success=True`, lo cual significa que el criterio de convergencia no fue satisfecho. Esto se debe a la geometría plana de la función de pérdida cerca del óptimo y a la simetría del modelo, pues:

$$\theta_1 \cdot \sin(\theta_2 x + \theta_3) = -\theta_1 \cdot \sin(\theta_2 x + \theta_3 + \pi)$$

lo cual produce soluciones equivalentes con θ_1 de signo opuesto, como se observa en las distintas inicializaciones(código adjunto).

Finalmente con respecto a la **calidad del ajuste**, las métricas solicitadas entregaron los siguientes resultados:

Table 2. Métricas modelo $f^{\text{pol}} + \sin$ en test			
ECM	EAM	R2	MSLE
1,459,109.35	975.62	-0.6971	0.6831

Comparado con las métricas del polinomio de grado 1 sin componentes sinusoidales (observar Tabla 1), el modelo actual mejora en todas las métricas, lo que evidencia que la oscilación captura parte de la estructura periódica de los datos. Sin embargo, el R^2 negativo indica que el modelo **aún predice peor que la media en el conjunto de test**, lo cual es visible en el gráfico pues la curva captura razonablemente la tendencia y la periodicidad en el tramo de entrenamiento, pero en la zona del test la amplitud de la senoide crece excesivamente por efecto del término $e^{\theta_4 x}$, mientras que los datos reales muestran una caída y mayor dispersión. Esto demuestra que el modelo sobreestima el crecimiento exponencial fuera de la muestra de entrenamiento, limitando su extrapolación y bajando en parte su calidad.

P2.6. Ajuste con Modelacion N°3

Se incorpora una segunda componente sinusoidal modulada por una exponencial, manteniendo fijos los parámetros de $f^{\text{pol-sin}}$ obtenidos en P2.5, entonces:

$$y = f^{\text{pol-sin}}(x) + \theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x} + \eta, \quad \eta \sim \mathcal{N}(0, \sigma_n^2)$$

Se optimizaron $(\theta_5, \theta_6, \theta_7, \theta_8)$ mediante MLE, donde se compara tres métodos: BFGS, Nelder-Mead y L-BFGS-B, obteniendo los siguientes resultados:

Table 3. Comparación de métodos de optimización para la segunda componente sinusoidal

Métrica	BFGS	Nelder-Mead	L-BFGS-B
Loss	33,753,761	33,753,615	33,754,394
Iteraciones	92	16,776	17
Eval. función	710	27,313	100
Convergió	No	Sí	Sí

Los tres métodos convergen a soluciones similares en términos de pérdida, pero con diferencias notables en eficiencia. **L-BFGS-B es el más eficiente computacionalmente**, por solo necesitar 17 iteraciones, en contraste con Nelder-Mead que requiere considerablemente más evaluaciones lo cual se debe probablemente al ser un método libre de derivadas. **BFGS no reportó convergencia formal**, aunque su pérdida es comparable. La **solución seleccionada corresponde a Nelder-Mead por obtener la menor pérdida**, con parámetros:

$$(\theta_5, \theta_6, \theta_7, \theta_8) \approx (-2.247 \times 10^5, 2 \times 10^{-4}, 3 \times 10^{-4}, -0.839)$$

Con respecto a las métricas para este nuevo modelo fueron las siguientes:

Table 4. Métricas modelo $f^{\text{pol-sin-sin}}$ evaluadas en test

ECM	EAM	R^2	MSLE
1,440,939.62	964.01	-0.6759	0.6741

Respecto al modelo N°2 (observar Tabla 2) la segunda componente sinusoidal produce una leve mejora en todas las métricas. Sin embargo, el R^2 continúa siendo negativo, lo cual indica que el modelo sigue sin superar a la media como predictor en el conjunto de test.




Figure 7. Grafo Modelo N°2

Como se observa, las curvas del modelo N°2 y el modelo N°3 son prácticamente iguales, lo cual significa que la segunda sinusoidal no aporta **capacidad expresiva significativa** adicional con los parámetros encontrados. En la zona del test, ambos modelos sobreestiman la cantidad de reseñas hacia el final de la serie, donde los datos reales muestran una caída pronunciada, solo que este nuevo modelo levemente es ligeramente inferior con esta sobreestimación. Esto indica que la componente exponencial $e^{\theta_8 x}$ con $\theta_8 < 0$ amortigua la oscilación, pero no logra capturar el quiebre estructural presente en los datos de test.

P2.7. Resultados y Discusión

Rol de cada componente del modelo final

El modelo final está compuesto por tres componentes con roles diferenciados:

- f^{pol} : El polinomio de grado 1, el cual captura la **tendencia global** de crecimiento sostenido en la cantidad de reseñas a lo largo del tiempo.

- $\theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x}$: La primera componente sinusoidal captura la **estacionalidad principal** de los datos, es decir, las oscilaciones periódicas de mayor amplitud que se observan en el tramo de entrenamiento.
- $(\theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x})$: La segunda componente sinusoidal intenta capturar **oscilaciones residuales** de menor escala que no fueron capturadas por la primera sinusoidal. Sin embargo, como se observó en P2.6, su contribución es muy ínfima.

¿Habría sido posible optimizar todos los parámetros simultáneamente?

Si es posible, pero presenta serias dificultades prácticas haciéndolo no conveniente. El modelo completo tiene 9 parámetros libres ($\theta_{\text{pol}}, \theta_1, \dots, \theta_8$), lo que genera una superficie de pérdida de alta dimensionalidad, no convexa y con múltiples mínimos locales. Optimizar todo simultáneamente aumenta el riesgo de quedar atrapado en un mínimo local desfavorable, lo cual hace más difícil elegir condiciones iniciales adecuadas y dificulta la interpretación de cada componente. El entrenamiento secuencial adoptado, fijando primero f^{pol} y luego añadiendo componentes, reduce la dimensionalidad del problema en cada etapa y facilita la convergencia.

Evaluación de modelos y equivalencia MLE–ECM.

Table 5. Comparación de métricas en test por modelo

Modelo	ECM	EAM	R^2	MSLE
f^{pol} (grado 1)	1,556,828	1,088.08	-0.81	0.74
$f^{\text{pol-sin}}$	1,459,109	975.62	-0.70	0.683
$f^{\text{pol-sin-sin}}$	1,440,939	964.01	-0.68	0.674

Se observa una mejora leve en todas las métricas al agregar componentes al modelo. Bajo ruido gaussiano, maximizar la log-verosimilitud es equivalente a minimizar el ECM, como se demostró anteriormente. Esta equivalencia se mantiene formalmente incluso cuando el modelo no es lineal en los parámetros, siempre que el supuesto de ruido gaussiano homocedástico sea válido. Sin embargo, dejarían de ser equivalentes en situaciones como:

- (1) cuando el ruido no es gaussiano
- (2) cuando existe heterocedasticidad y la varianza depende de x
- (3) cuando se incorporan términos de regularización a la función de pérdida, lo que corresponde a un enfoque MAP.

Comparación de métodos de optimización

BFGS y L-BFGS-B son métodos basados en gradiente que aproximan la Hessiana, siendo eficientes en iteraciones (observar Tabla 3) pero sensibles a irregularidades en el área de pérdida. Nelder-Mead, al ser libre de derivadas, requirió más evaluaciones (observar Tabla 3) pero encontró la menor

pérdida, lo cual sugiere que la superficie presenta zonas problemáticas para métodos basados en gradiente. En general los métodos de gradiente son preferibles ante funciones suaves, mientras que Nelder-Mead es más robusto cuando el gradiente es ruidoso.

P2.8. Análisis

Estimador MLE de σ^2 y heterocedasticidad.

El EMV de la varianza del ruido es:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n r_i^2 \approx 259,641, \quad \hat{\sigma} \approx 510 \text{ reseñas}$$




Figure 8. Residuos vs Tiempo (Train y Test)

En el gráfico de Train, los residuos se mantienen mayormente dentro de la banda $\pm \hat{\sigma}$ con media -0.74 , lo que indica un ajuste centrado en entrenamiento. Sin embargo, aparecen residuos positivos de gran magnitud a partir del índice 90, donde el modelo subestima estos outliers o peaks de actividad. En el gráfico de Test, el comportamiento se deteriora notablemente: la media cae a -441 y la desviación estándar sube a 1116 .




Figure 9. Residuos vs Valor predicho (Train y Test)

En el gráfico de Test, se aprecia un patrón sistemático donde los residuos varían según el valor predicho, evidenciando **heterocedasticidad**. Por lo tanto, el supuesto de varianza constante no se sostiene en los datos.

Supuesto gaussiano y datos de conteo.

Los datos corresponden a conteos enteros no negativos,

por lo que el supuesto de ruido gaussiano continuo es una aproximación.




Figure 10. Histogramas de Distribución de Residuos para Test y Train

En el histograma de Train, se observa asimetría con cola derecha pronunciada, alejándose de la simetría gaussiana esperada. Una distribución más apropiada para datos de conteo sería la **Poisson**, o la **Binomial Negativa**. **Quiebres estructurales**.

En el gráfico “Residuos vs tiempo (Test)” se identifica un período problemático en el final de la serie, donde los residuos son grandes y negativos, reflejando una caída abrupta en las reseñas que el modelo no anticipa correctamente. Esto hace sentido con el concepto de un quiebre estructural, posiblemente asociado a cambios externos, como la pandemia o algo similar. El modelo entrenado en un régimen de crecimiento sostenido, no tiene la capacidad para adaptarse a este tipo de cambios, lo cual deteriora significativamente su capacidad predictiva en test.

Incertidumbre epistémica e inferencia bayesiana.

El modelo actual produce predicciones puntuales sin cuantificar la incertidumbre sobre θ . Un enfoque bayesiano sería una buena opción, donde se obtendría una distribución posterior $p(\theta | \mathcal{D})$, y las predicciones se realizarían mediante la distribución predictiva conocida lo cual permitiría obtener **bandas de credibilidad** para las predicciones en lugar de una curva única.

References

Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.