

Tarea 3

Magíster en Ciencia de Datos

Autor: Matias CColque Antachoque¹ Profesor: Francisco Vásquez L.¹

Abstract

Se estudian distintos modelos de clasificación para predecir alguna enfermedad cardíaca utilizando el dataset Heart Disease. Se analiza el desempeño de Regresión Logística bajo distintas configuraciones de regularización e hiperparámetros, junto con la importancia relativa de las variables. Además, se comparan clasificadores como Perceptrón, KNN, Gaussian Naive Bayes y LDA mediante métricas Accuracy, F1-Score y AUC-ROC. Los resultados muestran que Gaussian Naive Bayes obtiene el mejor desempeño global y que la variable *ST_Slope_Up* presenta alta capacidad discriminativa.

P1. Inferencia Bayesiana

P1.1. Marco Teórico

El **enfoque generativo** modela la distribución conjunta $p(x, t)$, estimando $p(x | C_k)$ y $p(C_k) = \pi_k$ para obtener $P(C_k | x)$ via Bayes (p representa probabilidades continuas y P probabilidades discretas). En cambio, el **enfoque discriminativo** modela directamente $P(Y | X)$, sin supuestos sobre $p(x)$, donde Y representa la clase C_k y X las características.

(i) El LDA (Análisis Discriminativo Lineal) maximiza $p(x, t | \theta)$ con $\theta = \{\pi_k, \mu_1, \mu_2, \Sigma\}$, asumiendo gaussianas con covarianza compartida: y derivando (a, b) analíticamente. La Regresión Logística maximiza directamente $p(t | x; a, b)$, estimando (a, b) numéricamente sin modelar $p(x)$.

(ii) Aunque ambos modelos comparten la forma funcional $P(C_1 | x) = \sigma(a^\top x + b)$, la Regresión Logística es estrictamente discriminativa porque nunca especifica $p(x | C_k)$,

^{*}Equal contribution ¹Universidad de Chile, Santiago, Chile. Correspondence to: Matias CColque A. <matias.ccolque@ug.uchile.cl>.

por lo que sus parámetros no tienen interpretación generativa, haciendo que no se pueda aplicar Bayes.

(iii) LDA mejora su eficacia en el cálculo de (a, b) cuando existen pocos datos y cuando los supuestos gaussianos se cumplen, ya que la estructura provoca una reducción en la varianza. En contraste, la Regresión Logística es mejor cuando dichos supuestos se violan o cuando el tamaño muestral es grande.

P1.2. Particionamiento y Exploración

Se utilizó la semilla 42, donde se obtuvo del 80% de entrenamiento una cantidad de 735 observaciones y del 20% de test una cifra de 184 muestras. En la Tabla 1 se puede observar la proporción de clases, la cual se mantiene correctamente en ambos conjuntos (Train: 55.3% positivos, Test: 55.4% positivos), lo cual significa que la estratificación funciona correctamente.

Table 1. Estadísticas descriptivas para los conjuntos de entrenamiento y prueba.

Variable	Train (80 %)	Test (20 %)
Proporción HeartDisease = 1	0.5531	0.5543
Proporción HeartDisease = 0	0.4469	0.4457
Age (media)	53.85	52.16
Age (desv. estándar)	9.44	9.30
Cholesterol (media)	203.23	181.14
Cholesterol (desv. estándar)	108.40	111.78

La Figura 1 muestra la distribución de Cholesterol en ambos conjuntos. Se aprecia un peak pronunciado en 0, el cual corresponde a valores faltantes o no registrados, por ende se puede ignorar. Fuera de ese peak, la distribución es aproximadamente unimodal (un solo pico) centrada en torno a 200–250 mg/dL, con forma de colas hacia valores altos de la variable Cholesterol, siendo consistente entre Train y Test. La pequeña diferencia en medias se explica principalmente por la variabilidad de la cantidad muestral.




Figure 1. Distribución del Cholesterol en conjuntos

Estratificar es fundamental para garantizar que la proporción de la clase positiva ($HeartDisease = 1$) sea representativa en ambos conjuntos, evitando que una partición aleatoria genere sesgos en la evaluación del modelo.

P1.3. Regresión Logística Baseline

Se entrenó una Regresión Logística con hiperparámetros por defecto y con la misma semilla. Las métricas obtenidas se resumen en la Tabla 2, y las matrices de confusión se muestran en la Figura 2.

Table 2. Métricas del modelo baseline en Train y Test.

Métrica	Train	Test
Accuracy	0.8624	0.8859
Precision	0.8657	0.8716
Recall	0.8892	0.9314
Specificity	0.8293	0.8293
F1-Score	0.8773	0.9005
FPR	0.1707	0.1707
FNR	0.1108	0.0686

El modelo muestra un desempeño sólido y consistente entre Train y Test gracias a la similitud de los datos, rechazando la posibilidad de algún sobreajuste. Destaca que el Recall en Test supera al de Train, lo que indica que el modelo generaliza bien la detección de casos positivos.




Figure 2. Matriz de confusión para Train y Test

La **óptica discriminativa** nos dice que las métricas reflejan la calidad de la frontera de decisión lineal, lo cual se sustenta

por el alto valor de Precision y Recall, pues nos dicen que el hiperplano separa bien ambas clases en el espacio de features. Desde la **óptica generativa**, el Recall elevado implica que las probabilidades a posteriori $P(C_1 | x)$ son consistentemente altas para los verdaderos positivos, lo cual representa una buena estimación de la forma logística.

Respecto a la **asimetría de costos**, en un contexto clínico un FN (no detectar enfermedad) es notablemente más costoso que un FP, ya que implica dejar a un paciente enfermo sin tratamiento, esto es grave pues conlleva a un riesgo vital. El FNR obtenido en Test es relativamente bajo 0.06, lo que es favorable, pero idealmente debería minimizarse aún más mediante el ajuste del umbral de decisión.

P1.4. Sensibilidad al tamaño del Train

Se repitió el ajuste con una partición 60/40, obteniendo las métricas de la Tabla 3, junto a ello aparece las métricas de la partición 80/20, con el fin de comparar ambas directamente.

Table 3. Comparación de métricas entre particiones 80/20 y 60/40.

Métrica	80/20		60/40	
	Train	Test	Train	Test
Accuracy	0.8624	0.8859	0.8618	0.8723
Precision	0.8657	0.8716	0.8654	0.8829
Recall	0.8892	0.9314	0.8882	0.8873
Specificity	0.8293	0.8293	0.8293	0.8537
F1-Score	0.8773	0.9005	0.8766	0.8851
FPR	0.1707	0.1707	0.1707	0.1463
FNR	0.1108	0.0686	0.1118	0.1127

Los resultados son notablemente similares entre ambas particiones, con diferencias menores a 0.02 en todas las métricas. La métrica más sensible al cambio de partición es el **Recall** en Test, que cae de 0.9314 a 0.8873, y el **FNR**, que sube de 0.0686 a 0.1127, lo cual indica que con menos datos de entrenamiento el modelo detecta menos casos positivos.

Respecto al **dilema sesgo-varianza**, al reducir el conjunto de entrenamiento se esperarí un aumento en la varianza de las estimaciones, ya que cada muestra tiene una mayor influencia sobre los parámetros ajustados. Sin embargo, dado el tamaño del dataset, el impacto obtenido es moderado y por ende el modelo es estable para estimaciones.

P1.5. Curva ROC y AUC

La curva ROC grafica la tasa de verdaderos positivos (TPR) contra la tasa de falsos positivos (FPR). Esto permite evaluar el poder discriminativo del modelo más allá del umbral en el que se esté trabajando. El AUC resume esta curva en un escalar que va de $[0, 1]$, donde un valor de 1.0 indica clasificación perfecta y 0.5 equivale a un clasificador aleatorio (línea punteada en el grafo).

Los valores obtenidos se resumen en la Tabla 4, y las curvas ROC se muestran en la Figura 3:

Table 4. AUC para ambas particiones.

Partición	AUC Train	AUC Test
80/20	0.9327	0.9311
60/40	0.9325	0.9278




Figure 3. Comparación de Curvas ROC para particiones distintas

Ambas particiones logran un AUC superior a 0.93 lo que indica un excelente poder discriminativo. Como se observa en la Figura 3, la brecha entre las curvas Train y Test es mínima en ambos casos, confirmando una buena generalización. Sin embargo, la partición 80/20 produce un AUC de Test más estable numéricamente, con una diferencia Train-Test de apenas 0.0016 frente a 0.0047 en la partición 60/40. Esto es consistente con el dilema sesgo-varianza, donde se dice que una mayor cantidad de datos de entrenamiento reduce la varianza de las estimaciones, tal como lo observamos.

P1.6. Hiperparámetro de Regresión Logística

penalty: Define el tipo de regularización aplicada sobre los coeficientes. Por ejemplo L_2 penaliza la suma de cuadrados de los coeficientes (encogimiento), L_1 penaliza la suma de valores absolutos promoviendo *sparsity* (escasez), y *elasticnet* combina ambas penalizaciones mediante un parámetro radio.

C: Controla la intensidad de la regularización(λ) como $C = 1/\lambda$. Los valores pequeños de C implican mayor regularización (coeficientes más cercanos a cero), mientras que valores grande de C reducen la regularización, permitiendo que el modelo se ajuste más libremente a los datos(riesgo de overfitting).

class_weight: Permite asignar distintos pesos a cada clase durante el entrenamiento. Su objetivo es manejar desbalance de clases, enfocándose en la de mayor importancia. Por ejemplo, usar *class_weight = 'balanced'* ajusta automáticamente los pesos de forma inversamente proporcional a la frecuencia de cada clase, aumentando la importancia de la clase minoritaria en la función de pérdida.

P1.7. GridSearchCV

Se realizó validación cruzada con $K = 5$ sobre el conjunto de entrenamiento (80%), evaluando las 27 combinaciones de hiperparámetros posibles. Los resultados se muestran en la Tabla 5.

Table 5. AUC, Accuracy y F1-Score por combinación de hiperparámetros.

penalty	class_weight	C	AUC	Accuracy	F1
11	balanced	0.1	0.8967	0.8405	0.8540
12	balanced	0.1	0.9045	0.8392	0.8530
11	None	0.1	0.8970	0.8365	0.8542
12	None	0.1	0.9039	0.8433	0.8596
11	{0:1,1:5}	0.1	0.9063	0.7670	0.8208
12	{0:1,1:5}	0.1	0.9110	0.7792	0.8290
11	balanced	1.0	0.9066	0.8419	0.8559
12	balanced	1.0	0.9074	0.8433	0.8573
11	None	1.0	0.9064	0.8474	0.8635
12	None	1.0	0.9073	0.8460	0.8624
11	{0:1,1:5}	1.0	0.9131	0.7970	0.8408
12	{0:1,1:5}	1.0	0.9135	0.7970	0.8408
11	balanced	10.0	0.9078	0.8433	0.8573
12	balanced	10.0	0.9078	0.8433	0.8573
11	None	10.0	0.9076	0.8474	0.8637
12	None	10.0	0.9077	0.8487	0.8652
11	{0:1,1:5}	10.0	0.9139	0.8010	0.8442
12	{0:1,1:5}	10.0	0.9138	0.8010	0.8442
elasticnet	balanced	0.1	0.9008	0.8392	0.8530
elasticnet	None	0.1	0.9008	0.8419	0.8582
elasticnet	{0:1,1:5}	0.1	0.9087	0.7711	0.8235
elasticnet	balanced	1.0	0.9070	0.8419	0.8559
elasticnet	None	1.0	0.9068	0.8460	0.8624
elasticnet	{0:1,1:5}	1.0	0.9134	0.7970	0.8408
elasticnet	balanced	10.0	0.9079	0.8433	0.8573
elasticnet	None	10.0	0.9076	0.8474	0.8637
elasticnet	{0:1,1:5}	10.0	0.9138	0.8010	0.8442

En general, el AUC varía entre 0.8967 y 0.9139 con diferencias moderadas entre combinaciones. Las combinaciones con *class_weight* = {0 : 1, 1 : 5} obtienen un mayor AUC pero menor Accuracy, lo cual simboliza el intercambio entre priorizar la detección de positivos y la precisión general.

P1.8. Magnitud de los Coeficientes

Se ajustaron los 27 modelos directamente sobre el 80% de entrenamiento. La Figura 4 muestra la distribución de $\|\hat{\beta}_m\|_2$ por tipo de penalty, y la Figura 5 ilustra la relación entre C y la norma.




Figure 4. Histograma por tipo de penalty con la norma

Respecto al comportamiento de la norma con el tipo de penalty, se observa que el patrón de $l1$ presenta una distribución más dispersa con una frecuencia concentrada en $[1.4, 1.6]$ pero con valores altos en 2.2 (producto de las combinaciones con $class_weight = \{0 : 1, 1 : 5\}$), $l2$ concentra la mayoría de sus modelos en normas bajas ($[1.4, 1.6]$), con encogimiento uniforme de todos los coeficientes, y por último $elasticnet$ presenta un comportamiento similar a $l1$.




Figure 5. Grafo de comportamiento entre C y La Norma

Como se observa en la Figura 5 la magnitud de los coeficientes aumenta consistentemente con C para los tres tipos de penalty. Esto va de acuerdo a la teoría ($C = 1/\lambda$) dado que valores pequeños de C implican mayor regularización, forzando los coeficientes hacia cero. Entonces, en el límite $C \rightarrow 0$ se esperaría $\|\hat{\beta}_m\|_2 \rightarrow 0$, mientras que $C \rightarrow \infty$ elimina la regularización permitiendo normas arbitrariamente grandes.⁴

P1.9. Contribución relativa de variables

donde ST_Slope_Up es una variable dummy generada a partir de la variable original ST_Slope del dataset, que indica la pendiente del segmento ST en el electrocardiograma. Y justamente al ser Up, simboliza el caso de la pendiente ascendente.


Note que ST_Slope_Up aparece como variable dominante en los 27 modelos, independiente del tipo de penalty, lo que sugiere que su poder discriminativo es tan alto que ninguna configuración de regularización logra desplazarla.

Respecto a las propiedades de cada penalty, $l1$ promueve *sparsity* anulando coeficientes de variables menos rele-

Table 6. Variable dominante por modelo.

Modelo	penalty	C	class_weight	Var. dominante	$ \beta_{m,j} $
1	l1	0.1	balanced	ST_Slope_Up	0.5476
2	l2	0.1	balanced	ST_Slope_Up	0.5018
3	l1	0.1	None	ST_Slope_Up	0.5494
4	l2	0.1	None	ST_Slope_Up	0.5034
5	l1	0.1	{0:1,1:5}	ST_Slope_Up	0.5264
6	l2	0.1	{0:1,1:5}	ST_Slope_Up	0.4932
7	l1	1.0	balanced	ST_Slope_Up	0.5059
8	l2	1.0	balanced	ST_Slope_Up	0.5013
9	l1	1.0	None	ST_Slope_Up	0.5074
10	l2	1.0	None	ST_Slope_Up	0.5028
11	l1	1.0	{0:1,1:5}	ST_Slope_Up	0.4861
12	l2	1.0	{0:1,1:5}	ST_Slope_Up	0.4827
13	l1	10.0	balanced	ST_Slope_Up	0.5016
14	l2	10.0	balanced	ST_Slope_Up	0.5011
15	l1	10.0	None	ST_Slope_Up	0.5031
16	l2	10.0	None	ST_Slope_Up	0.5026
17	l1	10.0	{0:1,1:5}	ST_Slope_Up	0.4816
18	l2	10.0	{0:1,1:5}	ST_Slope_Up	0.4812
19	elasticnet	0.1	balanced	ST_Slope_Up	0.5238
20	elasticnet	0.1	None	ST_Slope_Up	0.5254
21	elasticnet	0.1	{0:1,1:5}	ST_Slope_Up	0.5095
22	elasticnet	1.0	balanced	ST_Slope_Up	0.5036
23	elasticnet	1.0	None	ST_Slope_Up	0.5051
24	elasticnet	1.0	{0:1,1:5}	ST_Slope_Up	0.4844
25	elasticnet	10.0	balanced	ST_Slope_Up	0.5014
26	elasticnet	10.0	None	ST_Slope_Up	0.5029
27	elasticnet	10.0	{0:1,1:5}	ST_Slope_Up	0.4814

vantes, por lo que es esperable que concentre aún más el peso en ST_Slope_Up . En cambio, $l2$ encoge todos los coeficientes uniformemente sin anularlos, distribuyendo más la importancia entre variables, aunque sin cambiar la variable dominante. Por último, $elasticnet$ combina ambos efectos, comportándose de forma intermedia. Sin embargo, dado que ST_Slope_Up domina en todos los casos, la elección de penalty afecta solo a la magnitud relativa de los coeficientes pero no altera la jerarquía de importancia entre variables.

Figure 6. Histograma por tipo de penalty para $|\tilde{\beta}_{m,j}|$ Table 7. Estadísticas de $|\tilde{\beta}_{m,j}|$ por tipo de penalty.

penalty	Media	Std	% zeros
l1	0.1839	0.1812	5.9%
l2	0.1895	0.1754	0.0%
elasticnet	0.1860	0.1791	5.2%

En la Figura 6, se observa que los tres paneles comparten un

patrón similar con alta concentración de registros cerca de cero y un peak pronunciado en torno a 0.5 correspondiente a ST_Slope_Up .

Segun la Tabla 7, las medias son similares entre los tres penalties lo que indica que en promedio la importancia se distribuye de forma parecida. Sin embargo, $l1$ y $elasticnet$ concentran más frecuencia en valores cercanos a cero, sugiriendo que pocas variables concentran la mayor parte de la relevancia, mientras que $l2$ distribuye la importancia de forma más uniforme entre todas las variables.

Finalmente, se calculó la distancia coseno de cada $\tilde{\beta}_m$ respecto a la mediana de los 27 vectores unitarios. La Tabla 8 resume los resultados.

Table 8. Distancia coseno respecto a la mediana.

Modelo	penalty	C	class_weight	dist. coseno
1	$l1$	0.1	balanced	0.014719
2	$l2$	0.1	balanced	0.000566
3	$l1$	0.1	None	0.014595
4	$l2$	0.1	None	0.000453
5	$l1$	0.1	$\{0 : 1, 1 : 5\}$	0.008807
6	$l2$	0.1	$\{0 : 1, 1 : 5\}$	0.010339
7	$l1$	1.0	balanced	0.000133
8	$l2$	1.0	balanced	0.000125
9	$l1$	1.0	None	0.000124
10	$l2$	1.0	None	0.000057
11	$l1$	1.0	$\{0 : 1, 1 : 5\}$	0.016875
12	$l2$	1.0	$\{0 : 1, 1 : 5\}$	0.017692
13	$l1$	10.0	balanced	0.000108
14	$l2$	10.0	balanced	0.000129
15	$l1$	10.0	None	0.000049
16	$l2$	10.0	None	0.000064
17	$l1$	10.0	$\{0 : 1, 1 : 5\}$	0.018680
18	$l2$	10.0	$\{0 : 1, 1 : 5\}$	0.018761
19	$elasticnet$	0.1	balanced	0.005668
20	$elasticnet$	0.1	None	0.005565
21	$elasticnet$	0.1	$\{0 : 1, 1 : 5\}$	0.008905
22	$elasticnet$	1.0	balanced	0.000076
23	$elasticnet$	1.0	None	0.000037
24	$elasticnet$	1.0	$\{0 : 1, 1 : 5\}$	0.017287
25	$elasticnet$	10.0	balanced	0.000118
26	$elasticnet$	10.0	None	0.000056
27	$elasticnet$	10.0	$\{0 : 1, 1 : 5\}$	0.018720

En general, las distancias coseno son muy bajas lo que indica que los 27 modelos apuntan en direcciones muy similares en el espacio de features. Los modelos con $class_weight = \{0 : 1, 1 : 5\}$ tienden a ser los más alejados de la mediana, ya que la mayor penalización de falsos negativos desplaza la frontera de decisión.

P1.10. Mejor combinación de hiperparámetros

Table 9. Mejores hiperparámetros según métricas.

Métrica	pen.	C	c.weight	AUC	F1	$\ \hat{\beta}\ _2$
AUC	l1	10	$\{0 : 1, 1 : 5\}$	0.9139	0.8442	2.2932
F1	l2	10	None	0.9077	0.8652	1.5853
Acc	l2	10	None	0.9077	0.8652	1.5853

Las mejores combinaciones **no coinciden** entre las métricas, pues AUC apunta a $l1$ y F1 junto a Acc van por $l2$, lo que sugiere una decisión entre maximizar el poder discriminativo (AUC) y el balance entre precisión y recall (F1).

La mejor combinación por AUC usa $class_weight = \{0 : 1, 1 : 5\}$ lo cual indica que penalizar más los falsos negativos mejora la separación global entre clases, esto es relevante en el contexto clínico donde un FN tiene mayor costo. En consecuencia, esto sacrifica Accuracy ya que el modelo clasifica más casos como positivos.

Respecto a $C = 10$ en ambas combinaciones, esto significa **poca regularización** ($\lambda = 0.1$), permitiendo que los coeficientes se ajusten más libremente a los datos. Esto se refleja en las normas: $\|\hat{\beta}\|_2 = 2.2932$ (AUC) versus $\|\hat{\beta}\|_2 = 1.5853$ (F1), ambas entre las más altas observadas. Esto tiene relación con lo obtenido en (h), donde valores altos de C producen normas mayores al reducir la penalización sobre los coeficientes.

Finalmente, en ambas métricas la variable dominante es ST_Slope_Up , que es lo esperable segun lo observado en (i), confirmando que esta variable concentra la mayor importancia independientemente de la métrica de selección utilizada.

P1.11. Comparación de clasificadores

Se entrenaron cinco clasificadores sobre la partición 80/20 de (b), donde se utilizó como mejor configuración de Regresión Logística la obtenida en (j) según AUC: $l1$, $C = 10$, $class_weight = \{0 : 1, 1 : 5\}$. Las métricas se resumen en las Tablas 10 y 11, con aproximación hasta el tercer decimal.

Table 10. Métricas en Train para todos los clasificadores.

Modelo	Acc	Prec	Rec	Spec	F1	FPR	FNR
Log. Reg.	0.812	0.755	0.978	0.607	0.852	0.393	0.022
Perceptron	0.555	0.554	1.000	0.003	0.713	0.997	0.000
KNN	0.781	0.794	0.815	0.738	0.804	0.262	0.185
GNB	0.852	0.863	0.870	0.829	0.866	0.171	0.131
LDA	0.858	0.865	0.882	0.829	0.873	0.171	0.118

Los resultados revelan diferencias notables entre modelos. El **Perceptrón** tiene el peor desempeño (Accuracy de 0.549 en Test con $FPR = 1.0$), clasificando prácticamente todo como positivo. Esto refleja su limitación como modelo

Table 11. Métricas en Test para todos los clasificadores.

Modelo	Acc	Prec	Rec	Spec	F1	FPR	FNR
Log. Reg.	0.810	0.752	0.980	0.598	0.851	0.402	0.020
Perceptron	0.549	0.552	0.990	0.000	0.709	1.000	0.010
KNN	0.696	0.726	0.726	0.659	0.726	0.341	0.275
GNB	0.913	0.930	0.912	0.915	0.921	0.085	0.088
LDA	0.891	0.880	0.931	0.842	0.905	0.159	0.069

discriminativo lineal con sensibilidad a datos no linealmente separables y a la escala de las características.

KNN muestra overfitting moderado (Accuracy 0.781 en Train vs 0.696 en Test), esperable en un modelo basado en instancias que memoriza el conjunto de entrenamiento. Su desempeño depende fuertemente de la escala de las características y del valor de k , lo que limita su generalización.

GNB presenta el mejor desempeño en Test (Accuracy = 0.913, $F1 = 0.921$). Aunque asume independencia condicional entre características, lo cual es un supuesto que no necesariamente se cumple. Su simplicidad actúa como regularización implícita, favoreciendo la generalización.

LDA obtiene resultados concretos ($F1 = 0.905$ en Test), lo cual va de la mano al ser un modelo generativo gaussiano con covarianza compartida, donde su frontera lineal se adapta bien a este dataset.

Para mejorar cada modelo, para **Perceptrón** escalar características y aumentar iteraciones, para **KNN** normalizar características y optimizar k , para **GNB** explorar transformaciones que refuercen la independencia condicional y para **LDA** solamente verificar supuestos gaussianos.

P1.12. ROC para todos los clasificadores

La Figura 7 muestra las curvas ROC para los cinco modelos, junto a los valores AUC: Log. Reg. 0.9341, Perceptrón 0.6883, KNN 0.7486, GNB 0.9451 y LDA 0.9271.




Figure 7. Curvas ROC para varios Clasificadores

Log. Reg. y LDA presentan curvas ROC similares pues ambos producen fronteras lineales de la misma forma,

$\sigma(a^T x + b)$, compartiendo la misma familia funcional. En datos aproximadamente balanceados, las diferencias en cómo estiman (a, b) (discriminativo vs generativo) tienen impacto menor, resultando en curvas similares.

GNB obtiene el mayor AUC pese a asumir independencia condicional entre características (supuesto difícilmente cumplido en datos clínicos). Su curva ROC supera a Log. Reg. y LDA, sugiriendo que las características aportan información discriminativa suficiente para que el supuesto no penalice el desempeño.

KNN obtiene una curva notoriamente más suave y alejada de la esquina superior izquierda. Como es un modelo basado en instancias sin supuestos distribucionales, su desempeño depende fuertemente de la escala de las características y del valor de k , limitando su poder discriminativo.

Perceptrón obtiene el peor AUC, apenas sobre el clasificador aleatorio. Al no producir probabilidades nativas sino solo una función de decisión lineal, su curva ROC es escalonada e inestable.

Los modelos que tienden a maximizar el AUC son aquellos que producen **probabilidades bien calibradas** (Log. Reg., LDA y GNB) ya que el AUC depende del ranking de scores (valor numérico que el modelo asigna a cada observación para indicar qué tan probable es que sea positiva) y no del umbral de decisión.

P1.13. Subconjunto de variables

Se evaluaron los cinco modelos sobre tres subconjuntos: solo variables categóricas, solo numéricas y todas. Los resultados se resumen en la Tabla 12.

Table 12. AUC, Accuracy y F1-Score por subconjunto y modelo.

Subconjunto	Modelo	AUC	Acc	F1
Categóricas	Log. Reg.	0.909	0.799	0.840
Categóricas	Perceptron	0.875	0.777	0.768
Categóricas	KNN	0.897	0.864	0.877
Categóricas	GNB	0.911	0.853	0.863
Categóricas	LDA	0.902	0.837	0.856
Numéricas	Log. Reg.	0.874	0.620	0.743
Numéricas	Perceptron	0.762	0.674	0.655
Numéricas	KNN	0.748	0.696	0.726
Numéricas	GNB	0.888	0.826	0.842
Numéricas	LDA	0.867	0.755	0.785
Todas	Log. Reg.	0.934	0.810	0.851
Todas	Perceptron	0.688	0.549	0.709
Todas	KNN	0.749	0.696	0.726
Todas	GNB	0.945	0.913	0.921
Todas	LDA	0.927	0.891	0.905

En general, el subconjunto **completo** produce el mejor de-

sempañ para la mayoría de modelos, significando que ambos tipos de variables aportan información complementaria que mejora la interpretación. Aun así es importante destacar que las **variables categóricas** resultan más informativas que las numéricas para casi todos los modelos, lo cual va de la mano con que *ST_Slope_Up* sea la variable dominante identificada en (i).

GNB es el modelo más robusto entre subconjuntos, manteniendo AUC alto tanto con categóricas como con numéricas. Esto se explica porque su supuesto de independencia condicional lo hace menos sensible a la estructura de correlación entre variables.

KNN muestra un contraste en su comportamiento, su AUC con categóricas supera ampliamente al de numéricas e incluso al obtenido con todas las variables. Esto sugiere que las variables numéricas introducen ruido en la métrica de distancia.

LDA y Log. Reg. se benefician claramente de usar todas las variables, esto se debe a su naturaleza paramétrica lineal que aprovecha la información conjunta de todas las características para estimar la frontera de decisión.

Perceptrón presenta comportamiento distinto entre subconjuntos, con AUC de 0.875 en categóricas pero solo 0.688 con todas las variables, evidenciando su sensibilidad a la escala y estructura de los datos.

P1.14. Mejor Modelo Global

Considerando los supuestos, métricas e interpretabilidad, se propone **GNB** como el mejor modelo global. A continuación, se explica el detalle de esta decisión.

(i) **Supuestos:** GNB asume independencia condicional entre características dado C_k , esto actúa como una regularización implícita. Además, como no asume covarianza compartida entre clases, es más flexible ante distribuciones asimétricas como *Cholesterol*.

(ii) **Métricas:** GNB obtiene el mejor desempeño en Test con $AUC = 0.9451$, $Accuracy = 0.913$ y $F1 = 0.921$, superando a todos los modelos. Además es robusto entre subconjuntos de variables, mostrando una gran validez ante información parcial que se tenga.

(iii) **Interpretabilidad:** Al ser un modelo generativo, GNB estima $p(x | C_k)$ y $P(C_k)$, permitiendo obtener las probabilidades a posteriori $P(C_k | x)$ directamente. Esto es valioso en el contexto clínico, donde conocer la probabilidad de enfermedad cardíaca es más útil que una simple clasificación binaria.

References

Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.