

Tarea 4

Fecha de entrega: 1 de junio de 2026, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Álvaro Márquez, Diego Olguín Wende.

Ayudantes: Tamara Carrasco, Javiera Yáñez.

Formato de entrega	PDF con extensión máxima de 8 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

A lo largo de esta tarea continuará trabajando con la base “Heart Failure Prediction” del archivo `heart.csv`, donde la variable objetivo es `HeartDisease`¹. Se asume disponible el preprocesamiento, los modelos baseline de Regresión Logística y el LDA ajustados en la Tarea 3.

Convenciones para toda la tarea: (i) clase positiva `HeartDisease=1`; (ii) genere variables *dummies*² con `drop_first=True` para evitar colinealidad perfecta; (iii) reutilice la misma semilla y la partición 80/20 estratificada empleada en la Tarea 3, de modo que los resultados de ambas tareas sean directamente comparables; (iv) cuando se solicite “reportar métricas”, considere el conjunto $\mathcal{M} = \{\text{Accuracy, Precision, Recall, Specificity, F1-Score, FPR, FNR}\}$.

P1. Teoría de la información y selección de modelos

El objetivo de esta pregunta es formalizar la elección entre modelos de la misma familia funcional (Regresión Logística y LDA, ambos con frontera lineal en x) mediante criterios fundados en teoría de la información, en lugar de comparar únicamente métricas empíricas como en la Tarea 3.

(a) **Marco teórico.** Defina formalmente los siguientes conceptos vistos en clase:

- Entropía de una variable aleatoria discreta X : $H(X) = -\sum_x p(x) \log p(x)$.
- Información mutua entre X e Y : $I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$.

¹ <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

² https://pandas.pydata.org/docs/reference/api/pandas.get_dummies.html

- Divergencia de Kullback-Leibler entre dos distribuciones p y q : $D_{\text{KL}}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$.

Demuestre (o justifique con detalle) la identidad $I(X;Y) = H(Y) - H(Y | X)$ y discuta su interpretación: ¿en qué sentido $I(X;Y)$ mide la información que aporta X sobre Y ? Comente además qué condiciones cumple D_{KL} (no negatividad, asimetría) y por qué no es una métrica en sentido estricto.

(b) **Criterios de información: AIC y BIC.** Presente las fórmulas

$$\text{AIC} = -2\hat{l} + 2d, \quad \text{BIC} = -2\hat{l} + d \ln N,$$

donde $\hat{l}$ es la log-verosimilitud maximizada, d el número de parámetros estimados y N el tamaño de la muestra. Discuta:

- Motivación de AIC desde la divergencia KL:* explique brevemente por qué Akaike propuso AIC como una estimación asintóticamente insesgada de la KL esperada entre el modelo ajustado y el modelo generador de los datos.
 - Motivación de BIC desde la inferencia Bayesiana:* explique cómo BIC aproxima $-2 \log p(\mathcal{D} | \mathcal{M})$ (log-evidencia marginal) vía la aproximación de Laplace y por qué la penalización resulta $d \ln N$.
 - Comparación de penalizaciones:* ¿a partir de qué tamaño muestral N la penalización de BIC supera a la de AIC? Comente la noción de *consistencia* de BIC y *eficiencia* de AIC (mencione, sin demostrar, el Teorema de Stone-Shao).
- (c) **Selección de variables vía información mutua.** Sobre el conjunto de entrenamiento de la Tarea 3 (tras codificación dummy), calcule el estimador empírico $\hat{I}(X_j; Y)$ para cada variable X_j (puede usar `sklearn.feature_selection.mutual_info_classif`³). Reporte el ranking de variables y, a partir de éste, defina tres modelos de Regresión Logística:
- M_1 : todas las variables disponibles.
 - M_2 : las k variables con mayor IM (justifique su elección de k ; un valor razonable es $k = 5$).
 - M_3 : un subconjunto contrastante (por ejemplo, las k variables con menor IM, o un subconjunto compuesto exclusivamente por variables categóricas/numéricas). Justifique.

Comente las limitaciones del estimador de información mutua cuando coexisten variables continuas y *dummies* (discretización, supuestos de independencia, sensibilidad al tamaño muestral).

(d) **Cálculo de AIC y BIC para Regresión Logística.** Para cada $M \in \{M_1, M_2, M_3\}$:

- Ajuste un modelo de Regresión Logística sobre el conjunto de entrenamiento. Para que la log-verosimilitud sea comparable entre modelos, utilice un valor de C suficientemente grande (e.g. $C = 10^6$) de modo de aproximar el ajuste por máxima verosimilitud sin regularización, o bien emplee `statsmodels.Logit`. Justifique brevemente la elección.
- Calcule $\hat{l}$ sobre el conjunto de entrenamiento. (*Sugerencia: utilice `predict_log_proba` y sume las log-probabilidades de la clase observada, o emplee directamente el atributo `llf` de `statsmodels`.*)
- Determine d como el número de coeficientes estimados (incluyendo el intercepto).

³ scikit-learn.org/stable/modules/generated/sklearn.feature_selection.mutual_info_classif.html

- (iv) Calcule AIC y BIC.
- (v) Estime el F1-Score por validación cruzada estratificada $k = 5$ sobre el conjunto de entrenamiento.
- (e) **AIC y BIC para LDA.** Considere el LDA ajustado sobre el conjunto de entrenamiento (con todas las variables, como en la Tarea 3).
 - (i) Escriba explícitamente la log-verosimilitud conjunta $\log p(\mathbf{x}, \mathbf{t} \mid \theta)$ del modelo gaussiano con covarianza compartida, con $\theta = \{\pi_k, \mu_k, \Sigma\}$, y evalúela en los estimadores de máxima verosimilitud para obtener $\hat{l}$.
 - (ii) Determine d contando explícitamente los parámetros libres que estima el modelo LDA con covarianza compartida: priors de clase, vectores de medias y matriz de covarianza. Indique cuántos parámetros libres aporta cada componente en función del número de clases K y de variables explicativas M , y obtenga la expresión final para d . Evalúela para $K = 2$ y el valor de M correspondiente al *dummy encoding* del dataset.
 - (iii) Calcule AIC y BIC, y la F1-CV ($k = 5$) sobre el conjunto de entrenamiento.
 - (iv) Comente brevemente si los supuestos de normalidad por clase y homocedasticidad parecen plausibles en **heart.csv**, considerando la presencia de variables *dummy*.
- (f) **Tabla comparativa y fuerza de la evidencia.** Reporte una tabla con $\hat{l}$, d , AIC, BIC y F1-CV para los cuatro modelos $\{M_1, M_2, M_3, \text{LDA}\}$. Responda:
 - (i) ¿Coinciden AIC y BIC en el modelo preferido? Si no, ¿qué modelo prefiere cada criterio y por qué (en términos de la penalización por complejidad)?
 - (ii) Calcule $\Delta\text{AIC}_M = \text{AIC}_M - \min_{M'} \text{AIC}_{M'}$ y análogamente ΔBIC_M . Investigue por su cuenta reglas heurísticas para interpretar diferencias ΔAIC y ΔBIC (por ejemplo, los umbrales propuestos por Burnham y Anderson para ΔAIC y por Kass y Raftery para ΔBIC). Cite la fuente consultada, resuma los umbrales que reporta y aplíquelos a sus resultados: ¿qué nivel de evidencia respalda al modelo preferido?
 - (iii) Conecte el resultado con (a) y (b): ¿qué significa elegir el modelo con menor AIC desde la perspectiva de la divergencia KL al modelo generador?
 - (iv) ¿Es coherente el ordenamiento por AIC/BIC con el ordenamiento por F1-CV? Si no, ¿qué interpretación da a la discrepancia (e.g. posibles errores de especificación, comportamiento en *small samples*)?

P2. Support Vector Machines

- (a) **Marco teórico.** A partir de lo visto en clase, derive o justifique brevemente:
 - (i) El problema primal del SVM de margen duro: $\min_{w,b} \frac{1}{2} \|w\|^2$ sujeto a $t_n(w^\top x_n + b) \geq 1$ para todo n . Explique por qué maximizar el margen equivale a minimizar $\|w\|$.
 - (ii) La extensión a margen suave mediante variables de holgura $\xi_n \geq 0$, y el rol del hiperparámetro C como compromiso entre el ancho del margen y el incumplimiento de la restricción de separabilidad.
 - (iii) La formulación dual y la aparición del producto interno $\langle x_i, x_j \rangle$. Use este resultado para motivar el *kernel trick*: definir un kernel $k(x_i, x_j)$ que corresponda a un producto interno en un espacio de características ϕ sin construir ϕ explícitamente.

- (iv) Presente las formas explícitas de los kernels **linear**, **poly**, **rbf** y **sigmoid** de **sklearn** y comente brevemente el tipo de superficie de decisión implícita que cada uno induce.
- (b) **SVC con hiperparámetros por defecto.** Sobre la misma partición 80/20 utilizada en P1 y en la Tarea 3:
- Entrene **sklearn.svm.SVC** con todos los hiperparámetros por defecto. Comente: dado que el kernel por defecto es RBF, ¿es necesario estandarizar las variables numéricas? Justifique y aplique el preprocesamiento que considere apropiado (sin incurrir en *data leakage*).
 - Reporte la matriz de confusión y las métricas $\mathcal{M}$ tanto para el conjunto de entrenamiento como para el conjunto de prueba. Comente eventuales signos de sobreajuste o de sensibilidad al desbalance de clases.
 - Genere la curva ROC y reporte el AUC sobre el conjunto de prueba utilizando **decision_function** (note que SVC no entrega probabilidades de manera nativa, a diferencia de la Regresión Logística). Interprete el valor obtenido y compárelo con el AUC de Regresión Logística reportado en la Tarea 3.
- (c) **Optimización de hiperparámetros con GridSearchCV.** Sobre el conjunto de entrenamiento, realice una búsqueda exhaustiva con validación cruzada estratificada $K = 5$ considerando todas las combinaciones de:
- kernel:** {'linear', 'poly', 'rbf', 'sigmoid'},
 - C:** {0.1, 1, 10},
 - class_weight:** {None, 'balanced', {0:1, 1:5}}.

Nota técnica: para kernels que dependen del parámetro **gamma** (**rbf**, **poly**, **sigmoid**) puede dejar el valor por defecto ('scale'); si lo desea, agregue **gamma** $\in$ {'scale', 'auto'} a la grilla y reporte la elección óptima. Como criterio principal de selección utilice F1-Score (o AUC; declare cuál usa). Reporte:

- La combinación de hiperparámetros que optimiza el criterio elegido.
 - Las métricas AUC, Accuracy y F1-Score sobre los conjuntos de entrenamiento y prueba con el mejor modelo.
 - Una comparación con el modelo por defecto de (b): ¿cuánto mejoró el rendimiento? ¿En qué métricas la mejora es más notoria?
- (d) **Interpretación de los hiperparámetros seleccionados.** Discuta cada uno de los hiperparámetros ganadores:
- kernel:** ¿qué sugiere el kernel elegido sobre la geometría de la frontera de decisión en **heart.csv**? ¿La elección es coherente con la dimensionalidad y mezcla de variables del dataset?
 - C:** interprételo como parámetro de regularización. ¿ C pequeño implica fronteras más rígidas (margen ancho, mayor sesgo) o más flexibles (margen estrecho, menor sesgo)? Conecte con la teoría de la parte (a).
 - class_weight:** ¿la elección óptima es consistente con lo observado en la Tarea 3 respecto del balance de clases? ¿Qué implicaría escoger {0 : 1, 1 : 5} desde el punto de vista de la verosimilitud ponderada?

- (e) **Comparación integradora.** Construya una tabla final con los modelos $\{M_1, M_2, M_3, \text{LDA}, \text{SVM}_{\text{best}}\}$ reportando, cuando corresponda: F1-CV, F1-test, AUC-test, AIC y BIC. Observe que AIC/BIC tal como se calcularon en P1 **no aplican directamente al SVM**: el SVM no maximiza una log-verosimilitud paramétrica de la conjunta $p(x, y)$ ni de la condicional $p(y | x)$. Comente brevemente esta limitación e investigue por su cuenta al menos una alternativa para acotar la complejidad de un SVM (por ejemplo, *Structural Risk Minimization* de Vapnik o cotas basadas en el margen); cite la fuente consultada y resuma la idea principal en pocas líneas. Luego responda:
- (i) ¿Qué modelo seleccionaría finalmente para predecir falla cardíaca? Justifique balanceando rendimiento predictivo, parsimonia y plausibilidad de los supuestos.
 - (ii) ¿Existe tensión entre el modelo preferido por AIC/BIC y el preferido por F1-test/AUC-test? Si la hay, discútala a la luz del compromiso sesgo-varianza y de las propiedades asintóticas de cada criterio.
 - (iii) Limitaciones generales del análisis: ¿qué patrones del dataset (no linealidades, interacciones, ruido en variables continuas) podrían no estar siendo capturados por LDA o por una Regresión Logística sin transformaciones de variables? ¿Cómo aporta el SVM con kernel no lineal en este aspecto?