
Tarea 4

Magíster en Ciencia de Datos

Autor: Matias CColque Antachoque¹ Profesor: Francisco Vásquez L.¹

Abstract

Esta investigación estudia criterios de selección de modelos basados en teoría de la información (AIC, BIC, información mutua) y máquinas de soporte vectorial (SVM) aplicados al dataset *heart.csv* para predecir falla cardíaca. Se comparan cuatro modelos: tres variantes de Regresión Logística ($M1$, $M2$, $M3$), LDA y SVM con kernel RBF, siendo este último el de mayor capacidad predictiva con AUC-test = 0.9464 y F1-test = 0.8986.

P1. Teoría de la Información y selección de modelos

P1.1. Marco Teórico

La entropía de una variable discreta representa la incertidumbre promedio que se tiene sobre el valor de X , y en base a eso definir si esta es una variable determinista o posee un comportamiento más bien aleatorio. Importante destacar que es un valor no negativo, y alcanza su plenitud con una probabilidad uniforme.

La información mutua, representa la cantidad de entropía que se reduce al saber el conocimiento de una variable sobre otra, es decir de X sobre Y y viceversa(simétrica).

La divergencia de Kullback-Leibler, representa que tanta información se pierde al ser explicada la distribución p en función de la distribución q . La medición de esta cantidad es en bits. Y no es simétrica.

La información mutua puede expresarse como una relación directa con la entropía. Para eso se debe captar explícitamente el significado de ella. Representa como se reduce la entropía de una variable($H(Y)$) tras saber el conocimiento de otra, eso a punta a una resta de nuestra entropía, y justamente apunta a una condicional pues se usa el termino "al saber" que es similar al "dado que", de esta

^{*}Equal contribution ¹Universidad de Chile, Santiago, Chile. Correspondence to: Matias CColque A. <matias.ccolque@ug.uchile.cl>.

forma se garantiza que $H(Y|X)$, es el operador que resta, donde X representa la otra variable. Con esta definición en mente se asume que: $I(X; Y) = H(Y) - H(Y|X)$ sin necesidad de demostración.

Sobre D_{KL} cumple no negatividad gracias a la desigualdad de Jensen, que nos garantiza que $D_{KL} \geq Jensen$, donde Jensen es el caso donde el $\log()$ sale al exterior permitiendo que se operen las distribuciones y obteniendo valor 0. Se alcanza la igualdad con distribuciones iguales $p = q$. La asimetría se garantiza con probar los valores $q = 0, p > 0$ entrega un valor infinito para $D(p||q)$, pero un valor finito para $D(q||p)$, probando asimetría. No responde a una métrica por no cumplir simetría, y de forma extra desigualdad triangular.

P1.2. Criterios de Información

(i) AIC es un modelo que se base en el objetivo de hallar una función predictora lo más cercana a los nuevos datos ingresados, por dicha razón utiliza la D_{KL} pues le permite ver la cercanía esperada de las funciones. Con esto en mente se construye:

$$E_f[D_{KL}(f||g(\cdot | \hat{\theta}))] = E_f[\sum_x f(x) \log f(x)] - E_f[\sum_x f(x) \log g(x | \hat{\theta})]$$

Luego se centra en el segundo término, pues es donde aparece nuestra función $g()$, y como se busca minimizar el KL, se busca maximizar la log verosimilitud. El problema de usar esta, es que introduce un sesgo optimista. La solución ante esto, es que dicho sesgo es asintoticamente igual a d , con este concepto se crea el estimador AIC conocido por todos(2d penalización del sesgo), garantizando una estimación asintoticamente insesgada.

(ii) Como lo dice en su nombre, BIC utiliza el enfoque bayesiano es decir se basa en: $p(D | M) = \int p(D | \theta, M) p(\theta | M) d\theta$. Con esto en mente para maximizar dicha probabilidad, se usa la aproximación de Laplace para expandir el primer término de la integral, entonces:

$\log p(D | M) \approx \log p(D | \hat{\theta}, M) + \log p(\hat{\theta} | M) - \frac{d}{2} \log N + O(1)$. Se desprecia el $O(1)$ asumiendo un N bastante grande, con prior poca informativa y multiplicando por -2 se obtiene el BIC. Finalmente se establece eso para que la penalización $d \ln(N)$ represente la

curvatura de la log-verosimilitud.

(iii) A partir de $N = 8$, se tiene que $\ln(N) > 2$, por ende la penalización de BIC es más grande que la de AIC, pues este último solo tiene el valor fijo de 2. Se evidencia que BIC, prefiere modelos más simples y posee consistencia pues la penalización crece con N , es decir cuando esté el modelo verdadero dentro del conjunto de posibles representaciones, y $N \rightarrow \infty$, entonces se escoge con probabilidad 1. Sobre la eficiencia de AIC, se da en los casos donde el modelo verdadero no está en el conjunto candidato, pues prioriza en minimizar el error de predicción, por esa razón AIC prioriza modelos más complejos con mejores capacidades predictivas.

P1.3. Selección de variables vía información mutua

Se calculó $\hat{I}(X_j; Y)$ para cada variable del conjunto de entrenamiento. El ranking se presenta en la Figura 1.




Figure 1. Ranking de variables por $\hat{I}(X_j; Y)$.

A partir del ranking se definen tres modelos:

- **M1:** todas las variables disponibles (15 tras *dummy encoding*).
- **M2:** top $k = 5$ variables (*ST_Slope_Up*, *ST_Slope_Flat*, *ExerciseAngina_Y*, *Oldpeak*, *Cholesterol*), seleccionadas por presentar $\hat{I} \geq 0.07$ y una caída marcada en el ranking a partir de la sexta variable.
- **M3:** las 5 variables con menor $\hat{I}$ no nulo (*Age*, *FastingBS*, *ChestPainType_NAP*, *RestingBP*, *RestingECG_Normal*), como subconjunto contrastante de bajo poder discriminante.

Cuando coexisten variables continuas y *dummies*, el estimador de *mutual.info.classif* combina vecinos más cercanos para variables continuas y conteo de frecuencias

para variables discretas. Esto genera limitaciones como la discretización implícita hace que los valores de $\hat{I}$ no sean directamente comparables entre variables continuas y *dummies*. Además, el estimador es sensible al tamaño muestral: con pocas observaciones puede asignar $\hat{I} = 0$ a variables con señal débil.

P1.4. Cálculo de AIC y BIC

(i) Se ajustaron modelos de Regresión Logística con $C = 10^6$, aproximando el ajuste por máxima verosimilitud sin regularización. Esta elección se dió porque AIC y BIC requieren la log-verosimilitud maximizada $\hat{l}$. Usar regularización penaliza los coeficientes y sesga $\hat{l}$ a la baja, haciendo los valores no comparables entre modelos con distinto número de parámetros.

(ii) La log-verosimilitud $\hat{l}$ se calculó sumando las log-probabilidades de la clase observada sobre el conjunto de entrenamiento usando *predict.log_proba*. Los resultados se mostrarán más adelante.

(iii) El número de parámetros d corresponde al número de coeficientes más el intercepto: $d = 16$ para $M1$ y $d = 6$ para $M2$ y $M3$.

(iv) Los resultados se resumen en la Tabla 1.

Table 1. Métricas de selección para modelos de Regresión Logística.

Modelo	$\hat{l}$	d	AIC	BIC	F1-CV
$M1$	-239.32	16	510.64	584.22	0.8645
$M2$	-289.32	6	590.63	618.23	0.8504
$M3$	-474.92	6	961.84	989.43	0.6983

(v) $M1$ obtiene el menor AIC y BIC, siendo preferido por ambos criterios pese a tener mayor d , ya que su ganancia en $\hat{l}$ compensa la penalización por complejidad. $M3$, compuesto por variables de bajo poder discriminante, presenta el peor ajuste en todos los criterios.

P1.5. AIC y BIC para LDA

(i) La log-verosimilitud conjunta del modelo LDA gaussiano con covarianza compartida es:

$$\log p(\mathbf{X}, \mathbf{t} | \theta) = \sum_{n=1}^N [\log \pi_{t_n} + \log \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_{t_n}, \boldsymbol{\Sigma})]$$

evaluada en los estimadores MV, asumidos conocidos y demostrados en clases: $\hat{\pi}_k = N_k/N$, $\hat{\boldsymbol{\mu}}_k = \frac{1}{N_k} \sum_{t_n=k} \mathbf{x}_n$ y $\hat{\boldsymbol{\Sigma}} = \frac{1}{N-K} S_W$, donde S_W es la matriz de dispersión intra-clase, se obtiene $\hat{l} = -17441.75$.

(ii) Los parámetros libres del LDA con covarianza compartida son: $K - 1$ priors, $K \cdot M$ medias y $M(M + 1)/2$

entradas de la covarianza simétrica, resultando en:

$$d = (K - 1) + KM + \frac{M(M + 1)}{2}$$

Para $K = 2$ y $M = 15$: $d = 1 + 30 + 120 = 151$.

(iii) Los valores obtenidos son: AIC = 35185.50, BIC = 35879.88 y F1-CV = 0.8716.

(iv) Los supuestos de normalidad por clase y homocedasticidad son cuestionables en *heart.csv*, pues las variables dummy toman valores $\{0, 1\}$, lo que viola la distribución gaussiana asumida por LDA. Pese a esto, LDA obtiene el mejor F1-CV entre los cuatro modelos, lo cual significa que aunque no cumpla las condiciones es una buena estimación.

P1.6. Tabla comparativa y fuerza de la evidencia

La Tabla 2 resume los resultados para los cuatro modelos. Dado que AIC/BIC del LDA no son comparables con los de Regresión Logística, pues LDA y Regresión Logística maximizan verosimilitudes distintas (conjunta vs condicional), los análisis se restringen a $\{M1, M2, M3\}$.

Table 2. Comparativa de modelos: $\hat{l}$, d , AIC, BIC y F1-CV.

Modelo	$\hat{l}$	d	AIC	BIC	F1-CV
M1	-239.3	16	510.6	584.2	0.86
M2	-289.3	6	590.6	618.2	0.85
M3	-474.9	6	961.8	989.4	0.70
LDA	-17441	151	35185.5	35879.9	0.87

(i) AIC y BIC coinciden en preferir $M1$ como modelo preferido, ya que la ganancia en $\hat{l}$ respecto a $M2$ compensa la mayor penalización por complejidad ($d = 16$ vs $d = 6$).

(ii) Aplicando los umbrales de Burnham & Anderson (2002) para ΔAIC , donde se afirma que los valores > 10 indican evidencia muy fuerte contra el modelo alternativo, en nuestro caso se obtuvo que: $\Delta AIC_{M2} = 79.99$ y $\Delta AIC_{M3} = 451.20$, lo cual representa una evidencia a favor de $M1$ muy contundente. Luego según Kass & Raftery (1995) para ΔBIC los valores > 10 constituyen evidencia muy fuerte. Con $\Delta BIC_{M2} = 34.01$ y $\Delta BIC_{M3} = 405.21$, ambos criterios respaldan $M1$ de forma decisiva.

(iii) Elegir el modelo con menor AIC significa seleccionar el modelo cuya distribución ajustada está más cerca del verdadero generador de datos en términos de divergencia KL esperada, minimizando así la información perdida al aproximar f con $g(\cdot | \hat{\theta})$.

(iv) El ordenamiento por AIC y BIC es coherente con el de F1-CV, pues en ambos criterios: $M1 > M2 > M3$. Esto sugiere que las variables adicionales de $M1$ aportan información relevante y no ruido, por lo que la mayor complejidad se traduce tanto en mejor ajuste como en mejor capacidad predictiva.

P2. Support Vector Machines

P2.1. Marco Teórico

(i) El SVM de margen duro busca el hiperplano $w^\top x + b = 0$ que maximiza la distancia entre clases. La distancia de un punto al hiperplano es $\frac{|w^\top x + b|}{\|w\|}$, por lo que el margen es $\frac{2}{\|w\|}$. Maximizar el margen equivale entonces a minimizar $\|w\|$, sujeto a que todos los puntos estén correctamente clasificados, que es la condición dicha en la pregunta.

(ii) Cuando los datos no son linealmente separables se introducen variables de holgura $\xi_n \geq 0$ que permiten violaciones del margen penalizadas por C :

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_n \xi_n \quad \text{s.a.} \quad t_n(w^\top x_n + b) \geq 1 - \xi_n$$

C grande penaliza fuertemente los errores (margen chico) y C pequeño tolera más errores (margen ancho).

(iii) La formulación dual del problema de margen suave es:

$$\max_{\alpha} \sum_n \alpha_n - \frac{1}{2} \sum_{n, m} \alpha_n \alpha_m t_n t_m \langle x_n, x_m \rangle$$

La aparición y dependencia en productos internos: $\langle x_i, x_j \rangle$ permite aplicar el *kernel trick*: reemplazar $\langle x_i, x_j \rangle$ por $k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$, operando en espacios de alta dimensión sin construir ϕ explícitamente.

(iv) Los kernels disponibles en sklearn junto a su superficie de decisión son:

- $k_{\text{linear}}(x_i, x_j) = x_i^\top x_j$: frontera lineal.
- $k_{\text{poly}}(x_i, x_j) = (\gamma x_i^\top x_j + r)^d$: frontera polinomial de grado d .
- $k_{\text{rbf}}(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$: frontera no lineal suave (se ajusta a cualquier dimensión y comportamiento)
- $k_{\text{sigmoid}}(x_i, x_j) = \tanh(\gamma x_i^\top x_j + r)$: frontera similar a una red neuronal de una capa.

P2.2. SVM con hiperparámetros por defecto

(i) El kernel RBF calcula distancias euclidianas entre puntos, por lo que variables numéricas en escalas distintas dominarían el cómputo. Se estandarizaron las variables numéricas con *StandardScaler* ajustado únicamente sobre el conjunto de entrenamiento, evitando *data leakage*. Las variables dummy se mantuvieron en $\{0, 1\}$.

(ii) Las métricas se resumen en la Tabla 3 y las matrices de confusión en la Figura 2.

Las métricas de train y test son muy similares por lo cual se descarta sobreajuste. Además, el modelo muestra mayor

Table 3. Métricas SVC por defecto.

Métrica	Train	Test
Accuracy	0.8883	0.8859
Precision	0.8803	0.8857
Recall	0.9236	0.9118
Specificity	0.8445	0.8537
F1-Score	0.9014	0.8986
FPR	0.1555	0.1463
FNR	0.0764	0.0882




Figure 2. Matrices de confusión SVC por defecto.

Recall que Precision, priorizando la detección de casos positivos. Esto es idóneo para casos como diagnóstico médico.

(iii) La curva ROC se presenta en la Figura 3. El AUC obtenido es 0.9464, superior al de la Regresión Logística reportado en la Tarea 3 (0.9341), indicando mejor capacidad discriminante del SVC con kernel RBF.




Figure 3. Curva ROC — SVC por defecto (test).

P2.3. Optimización de hiperparámetros

Se realizó una búsqueda exhaustiva con validación cruzada estratificada $K = 5$ sobre 36 combinaciones, usando F1-Score como criterio de selección, pues en un contexto de diagnóstico médico interesa balancear Precision y Recall

(costo asimétrico de falsos negativos), mientras que AUC evalúa el modelo a todos los umbrales posibles sin considerar ese balance.

(i) La combinación óptima fue $kernel = rbf$, $C = 1$, $class_weight = None$.

(ii) Las métricas del mejor modelo coinciden exactamente con las del modelo por defecto (Tabla 3), con $AUC = 0.9464$ y $F1\text{-test} = 0.8986$.

Table 4. Métricas SVC mejor modelo (GridSearch).

Métrica	Train	Test
Accuracy	0.8883	0.8859
Precision	0.8803	0.8857
Recall	0.9236	0.9118
Specificity	0.8445	0.8537
F1-Score	0.9014	0.8986
AUC	—	0.9464
FPR	0.1555	0.1463
FNR	0.0764	0.0882

(iii) El modelo por defecto de sklearn ya utiliza $kernel = RBF$ y $C = 1$ por lo que el GridSearch recupera los mismos hiperparámetros y no hay mejora respecto al modelo de P2(b). Esto indica que la configuración por defecto de SVC es adecuada para este dataset.

P2.4. Interpretación de los hiperparámetros seleccionados

(i) La elección de RBF sugiere que la frontera de decisión óptima en el dataset es **no lineal**. Esto tiene coherencia por la mezcla de variables numéricas y dummies del dataset, donde las relaciones entre predictores y la clase difícilmente forman un hiperplano separador perfecto en el espacio original.

(ii) $C = 1$ representa un balance neutro entre margen amplio y penalización de errores. Un C pequeño prioriza el margen (mayor sesgo), mientras que un C grande reduce el margen para clasificar correctamente más puntos de entrenamiento (menor sesgo). $C = 1$ indica que el dataset no requiere una frontera muy flexible ni muy rígida para generalizar bien.

(iii) La elección óptima $class_weight = None$ indica que tratar ambas clases con igual peso es suficiente, lo cual tiene relación con el balance de clases observado en la Tarea 3 (aproximadamente 55% positivos y 45% negativos). Escoger $\{0 : 1, 1 : 5\}$ implicaría penalizar cinco veces más los falsos negativos, sesgando el modelo hacia mayor Recall a costa de Precision.

P2.5. Comparación integradora

La Tabla 5 resume los cinco modelos. AIC y BIC no aplican al SVM ni al LDA en comparación con los modelos de Regresión Logística dado que el SVM no maximiza una log-verosimilitud paramétrica, sino que minimiza una pérdida de bisagra (*hinge loss*).

Una alternativa para controlar la complejidad del SVM es el principio de *Structural Risk Minimization* (SRM) de Vapnik(1995) que acota el error de generalización mediante la dimensión VC del modelo:

$$R \leq R_{emp} + \sqrt{\frac{h(\log(2N/h) + 1) - \log(\delta/4)}{N}}$$

, donde la dimensión $VC(h)$ es el mayor número de puntos que el modelo puede separar de todas las formas posibles, h es la dimensión de VC, R es el riesgo real(error de generalización esperado) y R_{emp} el riesgo empírico. El SRM selecciona el modelo que minimiza esta cota, penalizando la complejidad sin requerir una verosimilitud explícita.

Table 5. Comparativa final de modelos.

Modelo	F1-CV	F1-test	AUC-test	AIC	BIC
$M1$	0.8645	0.9005	0.9292	510.64	584.22
$M2$	0.8504	0.8302	0.8789	590.63	618.23
$M3$	0.6983	0.6840	0.6227	961.84	989.43
LDA	0.8716	0.8688	0.9274	—	—
SVM_{best}	0.8768	0.8986	0.9464	—	—

(i) Se seleccionaría SVM_{best} como modelo final, ya que obtiene el mayor AUC-test (0.9464) y un F1-test competitivo (0.8986), sin requerir supuestos sobre la distribución de los datos(LDA) ni sacrificar variables informativas como $M2$. Su kernel RBF captura no linealidades que los modelos lineales no pueden representar.

(ii) Existe una leve tensión, pues AIC/BIC prefieren $M1$ dentro de los modelos de Regresión Logística, mientras que F1-test y AUC-test van por el modelo SVM_{best} . Esto refleja que AIC/BIC penalizan la complejidad bajo el marco paramétrico de la verosimilitud(favoreciendo parsimonia) mientras que las métricas de test capturan directamente la capacidad predictiva. En muestras finitas, un modelo más flexible como SVM puede generalizar mejor aun siendo más complejo, lo cual va de la mano con el compromiso sesgo-varianza.

(iii) Es importante recordar que LDA y Regresión Logística **asumen fronteras lineales** y, en el caso de LDA, **normalidad por clase**. Entonces los patrones no lineales, interacciones entre variables e irregularidades en **variables continuas** como *Cholesterol* no son capturados por estos modelos sin transformaciones. El SVM con kernel RBF opera en un espacio de características de dimensión infinita, permitiendo fronteras arbitrariamente complejas y capturando las relaciones sin obtener ϕ necesariamente.

References

- [1] Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.
- [2] Burnham, K.P. & Anderson, D.R. (2002). *Model Selection and Multimodel Inference*. Springer.
- [3] Kass, R.E. & Raftery, A.E. (1995). Bayes Factors. *JASA*, 90(430), 773–795.
- [4] Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. Springer.