

Tarea 5

Magíster en Ciencia de Datos

Autor: Matias CColque Antachoque¹ Profesor: Francisco Vásquez L.¹

Abstract

Se estudian métodos de reducción de dimensionalidad lineal (PCA, Kernel PCA, Fisher LDA) y no lineal (Isomap, t-SNE, UMAP) aplicados al dataset *Heart Failure Prediction*. PCA requiere 5 componentes para retener el 90% de la varianza, mientras Fisher LDA logra mejor separación entre clases en una sola dimensión. Entre los métodos no lineales, UMAP exhibe la mayor pureza por clase en sus proyecciones. Se discuten las implicancias de cada método para definir la mejor exploración visual y clasificación del dataset.

La Tabla 1 resume los valores propios y la varianza explicada por cada componente. PC1 y PC2 acumulan el 52,02% de la varianza; se requieren $d^* = 5$ componentes para superar el umbral del 90% (Figura 1). La distribución relativamente uniforme de los λ_j refleja que ninguna dirección domina claramente la variabilidad del espacio numérico.

Table 1. Valores propios y varianza explicada (PCA).

j	λ_j	Var. (%)	Acum. (%)
1	1.8305	30.47	30.47
2	1.2948	21.55	52.02
3	0.8735	14.54	66.56
4	0.8336	13.87	80.43
5	0.6438	10.72	91.15
6	0.5319	8.85	100.00

P1. Reducción de dimensionalidad supervisada

P1.1. Análisis de componentes principales

Se ajustó PCA sobre las $M = 6$ variables numéricas estandarizadas del conjunto de entrenamiento reutilizando el *StandardScaler* de la Tarea 4 (ajustado exclusivamente sobre train).




Figure 1. Varianza de componentes y acumulada

^{*}Equal contribution ¹Universidad de Chile, Santiago, Chile. Correspondence to: Matias CColque A. <matias.ccolque@ug.uchile.cl>.

Proceedings of the 42nd International Conference on Machine Learning, Vancouver, Canada. PMLR 267, 2025. Copyright 2025 by the author(s).

La Figura 2 muestra la proyección 2D sobre PC1 vs PC2. Ambas clases se solapan considerablemente aunque se aprecia una tendencia donde los puntos con *HeartDisease* = 1 tienden a valores más positivos en PC1, mientras que los casos sin enfermedad se concentran hacia valores negativos.




Figure 2. Análisis de las primeras 2 componentes principales

La Figura 3 muestra los *loadings* de las dos primeras componentes principales. En **PC1** destacan *Age* (+0.557) y *MaxHR* (-0.526), lo que sugiere una relación con la capacidad cardiovascular, ya que la frecuencia cardíaca máxima tiende a disminuir con la edad. Luego **PC2** está influida

principalmente por *Cholesterol*, *Oldpeak* y *RestingBP*, variables asociadas a factores de riesgo cardiovascular. Como se sabe que PCA busca explicar la mayor variabilidad de los datos y no necesariamente separar las clases resulta natural considerar métodos supervisados como Fisher LDA.




Figure 3. Loadings de PC1 y PC2

P1.2. Kernel PCA

Kernel PCA descompone la matriz de Gram centrada $K_{ij} = k(x_i, x_j)$ en lugar de $\hat{\Sigma}$, operando en un espacio de características implícito definido por el kernel. Se proyectó el conjunto de entrenamiento a dos dimensiones con kernels *rbf* ($\gamma \in \{0.1, 1, 10\}$) y *poly* ($d \in \{2, 3\}$); los resultados se muestran en la Figura 4.




Figure 4. Comparación de kernels con diferentes parámetros

Partiendo con la reacción en kernel RBF, es importante recordar que se define:

$$k(x, y) = \exp(-\gamma \|x - y\|^2)$$

Un γ pequeño provoca similitudes suaves entre puntos lejanos, produciendo una proyección continua con cierta tendencia de separación entre clases. Con $\gamma = 1$ la separación visual mejora levemente, concentrando la clase positiva hacia valores negativos de KC1. Con $\gamma = 10$ el kernel se vuelve muy local, es decir, solo puntos casi idénticos tienen similitud no nula, colapsando la mayoría

de los puntos en el origen y dejando unos pocos outliers aislados.

Con respecto al kernel polinomial, con $d = 2$ se obtiene una proyección similar al PCA estándar con solapamiento moderado entre clases. Con $d = 3$ la escala aumenta considerablemente por la amplificación polinomial, pero la separabilidad no mejora respecto a $d = 2$.

Relacionando todo lo anterior con PCA, ninguna configuración mejora sustancialmente la separabilidad visual observada en la parte (a), esto sugiere que la frontera entre clases no es capturable fácilmente con dos componentes no lineales.

P1.3. Fisher Discriminant

Es importante recordar que LDA busca la dirección w que maximiza:

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

donde S_B es la dispersión entre clases y S_W la intraclass. Para $K = 2$ clases el rango de S_B es 1, o sea que solo hay un vector entre medias, por lo que el problema generalizado de valores propios entrega una única dirección discriminante.




Figure 5. Histograma separado por clase en Disease y No Disease

La Figura 5 muestra la proyección 1D donde la clase *No disease* se concentra en valores negativos y *Disease* en valores positivos. Si bien existe un solapamiento moderado en torno a cero, esta separación es notablemente mejor que la de PC1 en la parte (a), donde ambas clases se solapaban en todo el rango.

Con respecto a fisher y su razón del porque supera a PC1, recordar que PCA maximiza varianza total sin considerar las etiquetas por lo que la dirección de máxima varianza no tiene por qué alinear las medias de clase. En cambio, fisher maximiza explícitamente la razón entre varianza interclase e intraclase, encontrando la dirección que mejor separa las medias relativo a la dispersión interna.

P2. Reducción de dimensionalidad No Lineal

P2.1. Aplicación inicial




Figure 6. Tipos de Proyecciones a 2 dimensiones

La Figura 6 muestra las tres proyecciones a dos dimensiones. **Isomap** produce una distribución continua con solapamiento considerable, sin separación clara entre clases. **t-SNE** genera agrupamientos compactos bien definidos, donde varios clusters son predominantemente de una clase, aunque sigue habiendo solapamiento. **UMAP** es el que mejor separación muestra pues forma clusters discretos con mayor pureza por clase, destacando grupos casi exclusivamente de *Disease* en los extremos del espacio.

P2.2. Sensibilidad a hiperparámetros




Figure 7. Grilla de UMAP según la mínima distancia

Con $n_neighbors = 5$ el grafo es poco conectado y aparecen ramas artificiales que distorsionan las distancias. Con $k = 15$ la proyección se estabiliza con cierta separación entre clases. Con $k = 50$ la estructura se vuelve más global y compacta, aumentando la separación. Entonces k controla el balance local y global, es decir valores pequeños capturan geometría fina pero son sensibles a ruido, en cambio valores grandes promedian demasiado.




Figure 8. Grilla de t-SNE

Con $perplexity = 5$ se generan clusters artificialmente pequeños y aislados sin estructura global. Con $perplexity = 30$ se observa una mejor separación, clusters compactos con mayor pureza por clase, aunque con un leve solapamiento. Con $perplexity = 100$ la estructura colapsa en una masa continua con fuerte solapamiento, pues el ancho de banda se vuelve tan amplio y se pierde la estructura local.




Figure 9. Grilla de UMAP según neighbors

Con $n_neighbors = 5$ la proyección captura estructura muy local, generando muchos clusters pequeños. Con $k = 15$ los clusters se consolidan con mejor separación entre clases. Con $k = 50$ predomina la estructura global: clusters más grandes y compactos, aunque algunos grupos mezclan ambas clases. Al igual que en Isomap, k regula el balance local y global, pero UMAP mantiene mejor la separación entre clases.




Figure 10. Grilla de t-SNE

El hiperparámetro min_dist representa la distancia mínima entre puntos en el espacio reducido dentro de la entropía cruzada que UMAP minimiza. Con $min_dist = 0$ los puntos se empaquetan al máximo, formando clusters muy compactos y bien separados. Con 0.3 los clusters se relajan manteniendo estructura útil. Con 0.8 los puntos se dispersan uniformemente y el solapamiento aumenta considerablemente, perdiendo separación entre clases.

P2.3. Interpretación

El balance local y global lo controla $n_neighbors$ en Isomap y UMAP, y $perplexity$ en t-SNE. En t-SNE, una perplejidad muy baja implica anchos de banda p_{ij} muy estrechos, por lo que cada punto solo interactúa con sus vecinos más inmediatos, generando clusters artificialmente aislados. Una perplejidad muy alta iguala las p_{ij} , haciendo que

las similitudes q_{ij} no puedan reproducirlas, produciendo colapso.

En UMAP, min_dist penaliza en la entropía cruzada que los puntos similares queden separados, por ende valores pequeños permiten empaquetamiento denso generando clusters compactos y valores grandes fuerzan dispersión uniforme deformando la estructura. En Isomap, $n_neighbors$ pequeño produce grafos poco conectados con distancias mal estimadas y demasiado grande distorsionan la variedad.

P2.4. Comparación con P1

Sí, t-SNE y UMAP revelan clusters con mayor pureza por clase que las proyecciones lineales de P1, donde existe solapamiento continuo. En particular, UMAP con $min_dist = 0.0$ forma grupos casi homogéneos imposibles de observar con PCA o Fisher, lo que sugiere que la estructura asociada a *HeartDisease* tiene componentes no lineales que los métodos lineales no capturan en dos dimensiones.

P4.Discusión Final

Situaciones donde la reducción ayuda al clasificador

La reducción de dimensionalidad ayuda cuando las variables originales contienen ruido, tal que el clasificador pueda operar en un espacio más limpio. Perjudica cuando se descartan direcciones informativas para la clase, como ocurre con PCA al ignorar las etiquetas. En P3, PCA con $d = 2$ probablemente degrada el rendimiento respecto al SVM original precisamente por esta razón.

Informativo para el dataset

Para exploración visual, t-SNE y UMAP resultaron más informativos al revelar estructura de clusters asociada a *HeartDisease*. Para interpretabilidad, Fisher LDA es el más útil al entregar una dirección con significado supervisado directo. Para clasificación, el SVM con kernel RBF sobre las variables originales sigue siendo la referencia más sólida.

Limitaciones Generales

Las principales limitaciones observadas son:

- Exclusión de variables categóricas del análisis de reducción, perdiendo información discriminante relevante.
- Supuestos implícitos de cada método (linealidad en PCA, normalidad en LDA, isometría en Isomap)
- Alta sensibilidad a hiperparámetros especialmente en t-SNE y UMAP

- Costo computacional creciente con N

Con más tiempo se abordarían mediante codificación aplicable para variables categóricas, búsqueda de hiperparámetros con validación cruzada y métodos de reducción que operen sobre el dataset completo.

References

- [1] Langley, P. Crafting papers on machine learning. In Langley, P. (ed.), *Proceedings of the 17th International Conference on Machine Learning (ICML 2000)*, pp. 1207–1216, Stanford, CA, 2000. Morgan Kaufmann.
- [2] Burnham, K.P. & Anderson, D.R. (2002). *Model Selection and Multimodel Inference*. Springer.
- [3] Kass, R.E. & Raftery, A.E. (1995). Bayes Factors. *JASA*, 90(430), 773–795.
- [4] Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. Springer.